

老师傅：将资深从业者的隐性经验 蒸馏为面向智能体的经验语料

老师傅平台研发团队¹

上海库帕思科技有限公司；同济大学

产品技术报告²，2026 年 9 月

摘要

资深从业者的专业经验不仅包含知识与结论，还涉及关键线索、判断依据、行动策略及适用边界，而这些隐性信息往往难以通过常规工作记录完整保留，限制了大语言模型智能体对专业经验的有效利用。本文提出以九层认知语料化技术为核心的经验工程平台“老师傅”，将异构工作资料与从业者访谈转化为可追溯、可复用、面向智能体的结构化经验语料。平台以情境、线索、判断、行动、边界和结果六类案例要素保留任务过程，以九个经验抽取维度组织隐性经验（九层认知语料化技术），并形成规则、约束、最佳实践、负样本、边界案例和技能六类经验资产。在此基础上，通过语义对齐、个体经验蒸馏、组织经验融合与交叉审核，保留经验的来源证据、适用条件及未解决分歧；进一步将经验资产组织为具有明确输入、执行步骤、依赖关系和停止条件的可调用技能，形成从经验获取到任务执行与评测反馈的完整流程。有效性验证方面，基于随机抽取的 20 位资深从业者授权测试样本，平台将 1,576 份原始资料整理为 23,024 条个人经验记录和 13,113 条组织经验资产。在涵盖多个专业领域的 177 道评测题、531 个回答样本上，基础模型、原始语料检索增强生成与老师傅智能体的综合平均得分分别为 70.63、79.75 和 89.58，老师傅智能体整体效果相较原始语料 RAG 提高 9.83 分，七个评分维度均呈现提升。系统性对比评测验证了老师傅平台及其核心的九层认知语料化技术在专业任务中的有效性，展现出其在任务质量、专业判断和经验复用方面的优势，为将个人隐性经验转化为组织知识资产与智能体能力提供了可实施的工程路径。

关键词：专家经验；隐性知识；经验语料；知识获取；智能体技能；组织知识；工程智能

1 引言

随着智能体加快进入企业生产与业务流程，依赖专业经验的工作任务对智能体理解任务情境、形成判断和选择行动提出了更高要求。将分散于资深从业者的实践与工作记录中的隐性经验转化为可追溯、可复用的经验语料，已成为支撑智能体可靠执行专业任务、降低关键经验流失风险的迫切需求。这一需求与国家推进人工智能赋能行业应用的战略方向相契合。国务院《关于深入实施“人工智能+”行动的意见》

¹详细团队成员见附录 A.

²官方网站：<https://lsf.kupasai.com/>.

提出促进专家知识的利用与复用，并加强高质量数据集建设 [1]。随后发布的制造业专项行动文件进一步提出工业数据集建设和面向生产任务的智能体应用 [2]。

在此背景下，如何将专业经验整理为人工智能系统可利用的知识，成为企业知识管理与智能化应用的重要课题。例如：维修专家可以结合异常声音、近期维修记录和运行负载来判断故障；调解员可以先核实存在争议的事实，再讨论责任。在这两类任务中，有用的经验不仅限于结论，还包括哪些证据起了作用、考虑了哪些替代方案、何种条件下适合采取哪项行动，以及何时应停止或调整流程。缺少这些条件，其他从业者或智能体就有可能将本来有用的规则套用到不适合的案例上。各行业的相关从业者在日常工作中，已保存了大量工作资料，包括手册、工单、事件报告、录音录像和案例复盘。但这些资料常常存在术语不统一、中间决策缺失、现场观察与事后解释混杂等问题。例如，某次成功处置可能留下了结果记录，却未记录促成该结果的关键条件；一些低频但后果严重的失败经验，也可能仅存在于口头交流中，因而难以通过文本检索获得。因此，如何从实际工作过程中获取和整理此类经验数据，一直是知识获取研究中的重要问题。典型方法之一是关键决策法，该方法通过围绕具体事件进行结构化追问，挖掘经验丰富的从业者在决策过程中关注的关键线索及其判断依据 [3-5]。

大语言模型为知识的组织与资料的利用提供了新的技术路径。检索增强生成（RAG）能够在推理过程中引入外部文本 [6]，基于图结构的检索进一步利用不同语料之间的关联关系 [7]，智能体框架则将模型推理与工具调用相结合 [8, 9]。然而，这些能力主要解决已有信息的检索、组织与调用问题，对于经验知识本身的形成与管理仍存在若干不足。例如，缺失的经验应如何补充，经验规则的适用条件应如何表达，不同经验陈述之间的冲突应如何处理，以及从工作记录中抽取出的流程是否具备实际可操作性。解决这些问题，需要进一步追溯智能体所依赖经验的获取、整理与审核过程。老师傅将这一过程概括为经验工程，即通过经验的获取、结构化、验证与持续维护，将分散于从业者和工作记录中的经验转化为可复用、可审查的知识资产。本文所称资深从业者，是指能够针对特定任务和具体情境提供实践经验的人员。系统将从业者经验与具体任务、适用条件和支撑证据关联，使专业判断能够被准确理解、审核与复用。围绕具体任务，平台对不同类型的工作记录进行整理，将经验内容、形成依据与适用条件关联保存，并通过版本管理记录经验的新增、修订与演化过程，从而为专家审核、来源追溯以及智能体后续调用提供基础，提升系统的可调、可信与可靠能力。

为评估平台的应用效果，本技术报告从已授权的平台用户中随机抽取 20 位来自不同专业领域的“老师傅”，对其语料、经验资产及运行记录进行整理和统计。该样本共包含 1,576 份原始资料、30,762 个语料片段、23,024 条个人经验条目和 13,113 条组织经验资产，分别对应资料采集、内容解析、经验提炼与组织融合等阶段。针对上述样本，评测在统一任务与评分标准下设置了三种智能体配置：仅使用基础模型的智能体（A 档）、原始语料 RAG 的智能体（B 档），以及调用老师傅经验与技能的智能体（C 档）。评测共包含 177 道题，在此基础上形成 531 个回答样本。对于每位老师傅，首先依据七项指标计算综合得分，再对 20 位老师傅的结果取平均，A、B、C 三组的平均得分分别为 70.63、79.75 和 89.58。上述结果验证了以九层认知语料化技术为核心的整体方案对专业任务表现的提升，详细结果与分析将在后续章节进一步展开。

总体而言，“老师傅”平台以九层认知语料化技术为语料处理核心，围绕专家经验的结构化表达、语料构建、组织融合、技能化应用与效果评测，形成了一套完整的经验工程流程，其核心贡献可分为四大部分。首先，**专家经验的结构化表示**连接六类案例要素、九个抽取维度和六类经验资产，为经验的采集、审核、追溯与智能体执行提供统一的数据表示。其次，**经验语料建设流程**面向异构工作记录，将原始资料转化为候选经验资产，并在转换过程中保留来源证据、上下文信息与审核状态。在此基础上，本系统进一步从经验的组织与应用两个层面展开研究。一方面，**组织经验融合**面向具体任务及其适用条件，对不同从业者的经验进行比较、归纳与整合：对于适用于不同情境的经验分别保留，对于存在冲突、分歧或证据不足的内容进行显式标记，并交由后续审核处理。另一方面，**技能构建与评测**将整理后的经验资产进一步转化为智能体可调用的操作流程，并通过基础模型、原始语料 RAG 和老师傅智能体三种实验设置进行对比，考察经验资产及其技能化表示对实际任务执行效果的影响。下文将依次介绍任务范围、经验结



图 1 老师傅平台系统概览：经验智能技术架构。

构化表示、经验语料建设和组织经验融合方法，并结合获得授权的样本说明各环节的具体实现。第 8 节进一步介绍评测方案，包括模型配置、输入信息以及运行资源等控制条件。

2 系统概览与任务范围

2.1 系统使用概览

“老师傅”系统的工作流程从边界明确的任务描述开始。任务描述应明确从业者角色、工作对象、作业环境、可用工具、触发条件以及单个案例的记录范围，同时规定任务完成的判定标准，并界定智能体能够执行和不得执行的决策范围。仅以“工业维修”等宽泛标签描述任务，难以形成可操作的经验采集边界。相比之下，更适宜的任务定义应具体到实际工作情境，例如：在特定运行条件下，对指定部件开展初步诊断，并将可执行操作限定为信息收集、问题分析和维修建议，不涉及未经授权的实际处置。在任务范围确定后，由从业者与采集助手共同制定任务说明和证据采集计划，围绕任务执行过程系统记录关键观察、判断与决策、异常情况以及最终结果。对于采集过程中发现的信息缺失，通过针对性的补充采集予以完善。例如，当诊断记录中缺少关键测量数据时，进一步查找原始测量记录，或通过访谈确认相关信息，从而建立事实、判断与结果之间清晰的证据链条。

以入选样本中的工伤纠纷调解员为例，其主要任务包括工伤性质与因果关系研判、赔偿项目核算、争议协商以及协议审核等。完成上述任务通常需要查阅责任认定材料、医疗证明、考勤记录、第三方赔付凭证等相关文件，并对事故发生经过及关键事实进行核实。任务说明还需进一步明确调解员的职责边界，即其主要提供调解和咨询支持，而不替代司法机关作出裁判；对于超出调解权限或经协商仍无法达成一致的争议，应按照既定程序转介至相应处理渠道。在明确任务范围、证据要求和职责边界后，经验采集即可围绕具体证据、判断依据、处置步骤及其适用条件展开，从而为后续经验的结构化表示与复用提供基础。

图 1 为老师傅平台的系统概览。具体的经验智能技术架构包含七步经验工程流程，其层级划分参考图 2。首先对任务范围和目标进行明确界定，随后由平台归集相关证据，并完成术语、实体与事件之间的对齐。

在此基础上, 从个人案例中抽取候选经验资产。之后, 通过组织经验融合对不同从业者形成的经验进行比较、归并与区分, 并通过交叉审核检查候选资产的证据依据、适用条件及表达准确性。本文沿用的平台任务名称“交叉验证”, 指经验内容的交叉审核与验证, 与机器学习中的 k 折交叉验证相区分。完成审核后的经验资产进一步用于智能体任务评测, 而评测结果又反馈至前端采集与整理环节, 为后续补充采集、资产修订和内容完善提供依据, 从而形成持续迭代的经验工程闭环。整个流程由两类相互关联但彼此独立的记录贯穿。案例记录用于描述一次具体任务执行过程中发生的事件, 包括任务背景、观察信息、采取的行动以及最终结果; 资产记录则用于描述从一个或多个案例中提炼出的、具有复用价值的经验内容。案例与资产之间形成多对多的关联关系: 一个案例可以为多项经验资产提供证据, 一项经验资产也可以由多个案例共同支撑。通过将案例记录与资产记录分离, 既能够完整保留原始事件及其证据链, 又能够在不修改原始事实的前提下, 对基于案例形成的经验归纳进行持续修订和完善, 从而兼顾经验的可追溯性、稳定性与可演化性。

图 2 老师傅的七步流程,按数据采集、经验构建和智能体评测分组。实线箭头表示处理顺序,虚线回路将评测发现的问题反馈至语料修订。每一阶段均保留来源引用、适用条件、审核状态和版本标识。

平台主要负责经验的获取、结构化表示、审核、筛选与持续维护；大语言模型承担任务理解与推理，领域工具则用于获取外部观察信息或执行经授权的操作。各类模型服务通过统一接口接入，以降低底层模型差异对上层流程的影响。为保证运行结果具备可追溯性和可复核性，系统应完整记录任务规范、模型及其版本、经验资产版本、检索配置以及工具权限等关键信息。当底层模型发生更换或升级时，应在其他条件保持一致的前提下，使用预先固定的同一批测试任务重新开展评测，以比较模型变化对系统整体性能的影响。具体部署环境与实现配置见第 10 节。

表 1 案例要素及其记录规范，分别保留事实、判断与执行状态，并显式标记缺失字段。

要素	内容	必须区分的情况
情境	任务、角色、对象、环境、时间和可用资源。	本案例中观察到的条件，与复用时假设的条件。
线索	工作中注意到的信号、测量、陈述和变化。	直接观察，与他人报告或推断得到的观察。
判断	解释、支撑理由、备选方案和不确定性。	从业者陈述，与模型生成的解释。
行动	选定操作、执行顺序、参数和终止条件。	计划采取、尝试过和实际完成的行动。
边界	禁止事项、适用范围、缺失前提和转交处理条件。	强制约束，与偏好或惯常做法。
结果	即时结果、后续核实和未确定的影响。	预期结果、报告结果和独立核实的结果。

3 专家经验的结构化表示

老师傅的经验表示由案例记录、经验抽取维度和经验资产类型三个部分构成，分别用于描述任务执行过程、刻画专家判断依据，以及组织可复用的经验内容，如图 3 所示。三者通过多对多关系相互连接：同一案例可以涉及多个经验维度，而同一技能的形成也可以综合调用多类经验资产。




图 3 九个经验抽取维度的组织示意。图中分支按照功能分组，展示九个维度在经验组织中的协作关系。案例要素用于记录具体任务过程，经审核的经验陈述可进一步组织为六类经验资产。经验维度与资产类型之间为多对多关系，例如一项技能可以同时综合注意、决策、习惯和约束等多个维度的信息。

3.1 任务案例

参照表 1，一个任务案例表示为

$$e = (c, u, j, a, b, o), \quad (1)$$

其中， c 为情境， u 为线索， j 为判断， a 为行动， b 为边界， o 为结果。上述六类要素统一组织案例信息，支持不同任务的实际执行顺序。对于任务过程中反复出现的判断与行动，可通过带有时间戳或偏序关系的事件进行表示，以保留其实际发生顺序和依赖关系。对于尚未得到明确结论的案例，保留结果待核实状态；对于尚未记录的判断依据，显式标记缺失并支持后续补充。

表 2 九层认知体系的抽取问题与代表性对象，抽取结果经证据和适用性审核后形成经验资产。

编号	层级名称	抽取问题	代表性对象
L1	知识层	用到了哪些事实与概念？	实体、术语、关系和领域资料。
L2	注意层	优先关注哪些观察信息？	诊断线索、忽略的干扰和关注点变化。
L3	判断层	什么依据支持该解释？	条件性判断、阈值、替代解释和不确定性。
L4	决策层	如何选择行动？	前提条件、选择标准和停止条件。
L5	联想层	哪些其他案例或概念与之相关？	类比、回忆的先例和跨案例关联。
L6	预判层	预期会出现什么后果？	预测影响、时间范围和后续核实。
L7	监控层	何时需要进一步检查？	知识缺口、不确定性和需要复核判断的情形。
L8	习惯层	哪些流程在不同案例中反复出现？	重复操作顺序、沟通惯例和偏好。
L9	约束层	哪些事情不能做？	禁止事项、适用范围和转交处理条件。

对于同一事件，可以同时保留多条相互独立的陈述。当不同从业者对某项观察或事实存在分歧时，应分别记录各自的陈述内容及其来源，而不应将存在争议的信息合并为单一、确定性的事实。类似地，即使后续行动最终解决了问题，前期无效或失败的行动仍应保留，因为这些过程能够反映从业者如何根据反馈调整判断和处置策略。若仅保留最终成功路径，将难以还原经验形成和策略修正的完整过程。

以样本中的工伤纠纷调解任务为例，可以用六类要素对案例进行结构化描述。其中，情境可表述为“建筑工地伤者就工伤赔偿申请调解”；线索包括责任认定材料、医疗证明、劳动关系证明和保险凭证等；判断主要涉及工伤待遇与第三方赔付之间的关系；行动包括赔偿项目核算、政策与责任释明、协商以及协议审核等；边界用于明确调解员无法替代司法裁判，并在争议无法通过调解解决时将案件转介至仲裁或诉讼程序；结果则既可以是双方达成调解协议，也可以是记录未解决争议并完成后续转介。通过上述六类字段，可以将同一案例中的事实信息、专业判断、处置行为、权限边界和最终结果分别记录并独立审核，从而提高经验表示的可追溯性和可复核性。

3.2 九层认知体系与经验抽取维度

九层认知体系为经验抽取与标注提供统一的术语框架，具体定义见表 2。L1 至 L9 的编号沿用平台既有方法论，分别对应相互协作、可交叉使用的经验抽取维度。为便于理解，图 3 进一步将九个维度归纳为“证据与情境”“判断与行动”“实践与监控”三组。三组从不同功能侧面组织经验，同一条经验陈述可以涉及多个维度或跨越不同分组。

注意层亦称注意力层，二者在本文中指同一经验维度。这些维度用于组织经验采集与审核中需要关注的内容，例如从业者关注了哪些信息、依据何种线索形成判断、采取了哪些行动，以及如何根据反馈调整后续策略。多个维度与多类经验资产共同构成完整的经验配置，整体评测检验其在专业任务中的综合效果。

在注意层的经验抽取中，需要有能够反映从业者实际关注重点的直接或间接证据，例如从业者本人对关注依据的说明、检查顺序记录或操作过程日志。仅依据模型内部的注意力权重，不能据此认定某种关注模式来源于从业者自身的经验 [10]。对于预判类经验，应同时记录预测内容、预期发生的时间范围以及后续实际结果，以区分事前判断与事后事实，避免将仅具有合理性的推测标注为已知事实。习惯维度用于描述在多个案例中反复出现的行为模式，但这种重复性本身并不意味着该行为构成必须遵循的操作要求。监控维度则用于记录从业者对自身判断、证据充分性或经验适用范围所表达的不确定性，从而保留经验使用过程中的条件限制与置信边界。




图 4 九条认知语料化管线的共享依赖与跨层映射。L1 指向 L2 至 L9 整体的箭头表示共用锚点映射表，以统一对象标识并追溯来源；各管线仍读取各自所需的原始语料。其余箭头表示有来源支持的依据引用、候选补充或复核约束。

3.3 人类思维经验的九层认知语料化技术

在上述九个经验抽取维度的基础上，本节介绍九层认知语料化技术，说明如何将异构原始材料中的事实陈述、判断依据和行动记录转化为可追溯的结构化经验单元。该技术按九个维度组织相互关联的抽取管线，以叙事性语料、显式推理、操作与反馈记录为基础，结合实体关系图和事件依赖图开展处理。首先，按时间对齐多源事件，仅合并对象及语义相容的重复记录，分别保留冲突陈述；再依据语义、任务阶段或反馈状态的变化切分认知片段，提取对象、证据、动作和结果等共用字段。同一片段可参与多个维度的抽取，各管线间的共享依赖与跨层映射如图 4 所示。下文分别说明各管线的抽取对象、处理方法与判定条件；具体算法根据数据条件选用，相关评分与阈值需经标注数据标定，输出均先作为待审核的候选语料。

L1 知识管线。 通过共指消解、实体链接和关系分类，将片段中的概念、对象和关系对齐到图谱。将片段 c_i 在图谱版本 ν 下的锚点映射记为 $\mathcal{M}_\nu(c_i) = (E_i, R_i, \Lambda_i)$ ，其中 E_i 、 R_i 分别为实体和关系集合， Λ_i 记录每项结果的原文位置与事件时间。同一实体的属性变化按时间保留版本，未确认链接保留候选。依据显式引用、判断或行动中的使用及撤回记录，区分仅被提及与有调用证据的知识，频次排序不自动删除低频关键知识。输出知识单元、属性版本及锚点映射；L2 至 L9 共用该映射完成对象对齐和来源追溯，同时读取各自所需的原始记录。

L2 注意管线。 通过注意提示语、依存句法和检查及选择日志定位关注对象，形成按时间排序的记录 $\mathcal{F} = \{(t_k, f_k, \ell_k)\}_{k=1}^m$ ，其中 f_k 为焦点对象或对象集合， ℓ_k 为来源锚点。仅在相邻观测均有效时记录对象转移，再结合描述和选择变化标定切换评分，未观测特征保留缺失。跨案例关注频率以同类任务中可观察该对象的机会为参照，经核对后归纳关注模式。输出关注对象、转移路径及证据类型，不将未提及视为被忽略，也不以模型注意力权重替代从业者证据。

L3 判断管线。 从显式推理中抽取判断目标、正反证据及排除条件，通过锚点连接条件与结论，压缩路径时保留中间前提。对适用前提满足、排除条件未触发且证据可评分的记录 x ，令 $q_r(x) \in [0, 1]$ 为规则

r 的已标定支持分，其审核建议可表示为

$$\text{status}_r(x) = \begin{cases} \text{支持}, & q_r(x) \geq \tau_+, \\ \text{待复核}, & \tau_- \leq q_r(x) < \tau_+, \\ \text{不采纳当前判断}, & q_r(x) < \tau_-, \end{cases} \quad 0 \leq \tau_- < \tau_+ \leq 1. \quad (2)$$

支持分不直接等同于正确概率；证据缺失时不赋零分，相反结论须另有证据。规则中的领域数值阈值可在明确似然及先验的贝叶斯模型中用 MCMC 估计后验；审核阈值 τ_- 、 τ_+ 则需用标注样本标定，低支持分不直接触发资产撤销；变化点检测限于有时间顺序且满足分段分布假设的数据。输出包含适用条件、成立与失效边界及证据引用的判断规则。

L4 决策管线。 抽取候选动作、排除理由及触发、终止和回退条件，将动作链接到操作节点。令 $\mathcal{C}(x)$ 为情境 x 的候选集合， $K(x, a)$ 表示相关事实及局部规则适用性已核实， $F(x, a)$ 为局部可行性条件， $H_r(x, a)$ 为适用局部禁限规则 $r \in \mathcal{R}_{\text{loc}}(x)$ 的满足条件，则

$$\mathcal{C}_{\text{loc}}(x) = \left\{ a \in \mathcal{C}(x) \mid K(x, a) \wedge F(x, a) \wedge \bigwedge_{r \in \mathcal{R}_{\text{loc}}(x)} H_r(x, a) \right\}. \quad (3)$$

仅纳入条件均确认成立的动作，未知者保留待复核。必做义务及跨动作互斥、时序由 L9 对完整方案联合检查，局部通过不代表整体合规。当 $|\mathcal{C}(x)| > 0$ 时，以 $\rho(x) = 1 - |\mathcal{C}_{\text{loc}}(x)|/|\mathcal{C}(x)|$ 描述已确认集合的缩减比例，未入选者不全等于不可行；单一候选仍需选择证据，空集则待澄清或转交。多案例条件与行动对可训练、剪枝 C4.5 决策树并以留出案例检验；状态、动作、转移及奖励特征模型明确时，可用最大熵逆向强化学习估计候选奖励。文本比较先形成准则偏序，专家补全成对比较并检查一致性后再以 AHP 计算权重。输出区分候选、计划、选定与已实施动作，不将候选奖励视为唯一真实偏好。

L5 联想管线。 从显式联想表达中定位起始概念 u 、目标概念 v 和桥接线索，以图上最短路径 $d_G(u, v)$ 及非零图嵌入的余弦相似度 $\cos(\mathbf{h}_u, \mathbf{h}_v)$ 描述结构跨度与语义接近程度。结合提示语、类比依据及共同属性筛选候选，保留图谱版本和评分依据。操作日志可用 PrefixSpan 挖掘频繁子序列，获得口述或其他过程证据后才标记为从业者联想。输出带桥接线索的联想单元及待核验关联，补充候选解释或备选行动；值得注意的是，图谱缺边不直接意味着认知跳跃，关联也不等同于因果。

L6 预判管线。 抽取当前状态、候选行动、预期后果和时间范围，建立预测事件节点，冻结预测时的信息、规则版本及时间戳。核对条件性预判时，先确认所指行动及触发条件实际成立，再按对象、结果定义和观察期限配对，未实施方案不直接配对真实结果。对相应结果已核实的配对 i ，以 $(\hat{y}_i, y_i)$ 、 $(\hat{\kappa}_i, \kappa_i)$ 和 $(\hat{t}_i, t_i)$ 表示预测与实际的数值、类别及事件时刻，按类型记录

$$e_i^{\text{num}} = \hat{y}_i - y_i, \quad e_i^{\text{cat}} = \mathbf{1}[\hat{\kappa}_i \neq \kappa_i], \quad e_i^{\text{time}} = \hat{t}_i - t_i. \quad (4)$$

其中 $\mathbf{1}[\cdot]$ 为条件成立时取 1、否则取 0 的指示函数；各类偏差保留各自单位，不混合相加。发生性预判在完整观察期内未发生事件时记为阴性结果，时间误差不定义；期限未滿或记录不完整者保持待核验。概率预测以有足够后续标签的独立样本检查校准，物理任务可另存状态及接触、支撑关系。值得注意的是，反事实推演须明确因果机制与识别假设，模拟差异不作为已验证的行动效果。输出包含预判、有效时间范围及核实记录。

L7 监控管线。 通过序列标注识别不确定、求证、修正及超出职责范围的表达，关联到具体命题 p 与证据。用 $z_t(p)$ 表示命题 p 在时点 t 的监控状态，记录怀疑、求证、撤回和核验恢复等转换及触发证据，避

免把话题变化当成状态变化。分别保存陈述确信程度、证据充分性、图谱缺失和职责边界，语言强度不直接换算为正确概率。输出知识缺口、待核验事项与复核条件，供判断和决策管线定位需重新检查的内容。

L8 习惯管线。 按从业者、任务类型和可比情境组织日志，将对象及动作归一为序列。对 $N > 0$ 个有效案例的动作序列 S_i ，定义非空模式 s 的案例支持度，并用插入、删除、替换代价均为 1 的 Levenshtein 距离 d_{edit} 比较同类流程：

$$\text{supp}(s) = \frac{1}{N} \sum_{i=1}^N \mathbf{1}[s \preceq S_i], \quad d_{\text{norm}}(S_i, S_j) = \frac{d_{\text{edit}}(S_i, S_j)}{\max\{1, |S_i|, |S_j|\}}. \quad (5)$$

其中 $s \preceq S_i$ 表示按顺序出现、不必连续的子序列， $|S_i|$ 为序列长度。同一案例内多次出现只计一次；支持度及距离须结合跨时间复现、样本量和例外检验稳定性。直接引语经对象及角色槽位化、语义归并后形成话术模板，输出原子操作、复合流程及可选话术配置。可引用 L4 中经日志核实的已实施动作进行跨案例归纳，并为 L5 提供序列关联候选，联想仍需桥接或过程证据。这些连接表示语料复用，不构成在线执行回路；观察到的习惯不直接等同于能力或强制要求。

L9 约束管线。 结合否定范围解析和规范来源核对，抽取适用前提、禁止事项、必须动作、责任边界及替代方案。对同一任务及约定时间窗，将主体、对象和发生实例纳入动作标识 a ，用布尔变量 X_a 表示是否执行，按需引入发生时刻 T_a 表达时序。令 $P_r(x)$ 为规则 r 的适用前提， $\mathcal{R}^-$ 、 $\mathcal{R}^+$ 分别为禁止和必须规则集，可构造

$$\Phi_x = \Phi_{\text{task}}(x) \wedge \bigwedge_{r \in \mathcal{R}^-} (P_r(x) \Rightarrow \neg X_{a_r}) \wedge \bigwedge_{r \in \mathcal{R}^+} (P_r(x) \Rightarrow X_{a_r}). \quad (6)$$

其中 a_r 为规则涉及的动作， Φ_{task} 编码已核实事实、前置、互斥及时序等条件，时刻约束仅对执行动作生效，不同范围分别建模。以可满足性模理论（SMT）检查 Φ_x ，可满足仅表示已编码条件存在一致解；含未知适用前提时，即使可满足也须补证复核，不把求解器赋值当作事实。无解或无法判定者转人工复核。先满足生效硬约束，再依据风险信号决定复核、降低输出粒度或抑制输出，评分不得覆盖硬约束。日志缺失不证明合规，输出保留依据、范围及审核状态。

通过上述九条管线形成的经验单元，统一保存案例及片段标识、图谱锚点、内容、条件、来源、审核状态和版本。层间映射先核对任务、对象及时间范围，再依据显式引用、时间邻近和内容一致性筛选与排序候选关联，并按来源证据标注为依据引用、候选补充或复核约束；分数达到阈值不自动确定关系类型或产生因果结论。其中可复用的内容经审核后，按用途组织为六类经验资产，并保留与原始案例及图谱的关联。质量控制包括结构完整性检查、证据与适用条件审核，以及面向具体任务的使用检查，不要求每个片段覆盖全部九个维度，也不以关联数量衡量质量。上述流程说明九个认知维度如何用于经验抽取与组织，下一节进一步讨论这些维度与脑区功能之间的启发性对应关系。

3.4 九层认知体系与脑区功能的对应分析

上述基于人类思维经验的九层认知语料化技术可以将异构原始输入转化为结构化语料，并在经验抽取、审核和复用中提供统一的术语框架。九层认知体系的设计参考了神经科学研究中对人类认知功能的分区与组织方式，旨在为经验抽取问题的设计、认知维度的解释以及后续消融实验提供启发。九层认知体系可与已有神经科学研究中描述的脑区及脑网络功能建立启发性的对应关系，如图 5 所示。本文依据相关文献中对不同脑区认知功能的研究，为 L1 到 L9 提供功能层面的参照。九层体系是面向专家经验组织与抽取的分析框架，借鉴脑区及脑网络的协同功能，建立多对多的功能参照。

已有研究表明，前颞叶及分布式联合皮层参与语义表征与整合，可为知识层 L1 和联想层 L5 提供功能参照 [11]；海马相关系统中的预测性表征能够联系既有关系与潜在后继状态，可为联想层 L5 和预判层 L6

提供启发 [12]。额眼区、顶内沟等区域参与目标导向的信息选择，与注意层 L2 所关注的选择性信息加工过程具有一定功能相似性 [13, 14]。此外，外侧前额叶参与情境依赖的认知控制，眶额皮层涉及价值表征与比较，可为判断、决策及规则维持等相关维度提供参照 [15, 16]；前部前额叶和前扣带皮层所涉及的自我监控、冲突检测与调整功能，则可为监控类经验提供功能上的类比 [17, 18]。

在行动与习惯方面，纹状体相关回路参与目标导向行为与习惯性反应的形成和调节，可为 L4 及习惯层 L8 提供参照 [19]；右额下回与反应抑制过程密切相关，可为 L4 和 L9 中涉及行动停止、约束与控制的内容提供部分功能参照 [20]。总体而言，这些对应关系属于多对多的功能类比，其作用主要是为经验抽取问题的设计、认知维度的解释以及后续消融实验提供启发。对于权限、禁止事项和适用边界等内容，系统仍通过显式记录、规则约束和审核机制进行管理。

3.5 六类经验资产库

经验资产用于将案例记录、从业者陈述以及权威规程中的可复用内容进行结构化封装，并服务于明确的任务场景。本文将核心经验资产划分为六类，即规则库、约束库、最佳实践库、负样本库、边界案例库和技能库。图中“优秀实践库”与“最佳实践库”同义，corner case 与边界案例、skill 与技能分别对应。其中，负样本库沿用平台既有命名，主要记录失败案例、失效做法及相应的纠正方法，并非机器学习分类任务中的负类训练样本；边界案例库对应平台中的非常规情形库，用于记录常规规则可能失效、需要调整或需采用特殊处理方式的情境，其范围并不限于数值阈值附近的案例。

经验抽取维度与经验资产类型通过多对多关系连接。L1 中涉及的事实、实体及其关系通常保留在案例记录或共享知识图谱中；L6 中的预判内容则与其预期时间范围和后续实际结果一并保留在案例中，也可进一步作为规则、技能或案例的适用条件。多个维度的信息由此共同支撑同一项经验资产。




图 5 脑区功能与九层认知体系的多对多对应，依据神经科学文献建立功能映射。上图为右半球外侧示意，下图为内侧与深部结构投影；字母与表格逐行对应，箭头标示大致对应区域。文献编号：N1 [11]; N2 [13]; N3 [14]; N4 [15]; N5 [16]; N6 [12]; N7 [17]; N8 [18]; N9 [19]; N10 [20]。

表 3 资产类型、语义及常见来源维度，各类资产支持跨维度组合。

资产类型	可复用内容	常见维度
规则	有适用范围的条件及其判断或行动建议，同时保留例外。	L3、L4
约束	禁止事项或强制前提、约束依据及允许的替代方案。	L7、L9
最佳实践	有证据支持的成功流程，以及可考虑复用的条件。	L1、L4、L5、L6
负样本	不当行动或不良结果、相关情境及经审核的纠正措施。	L3、L4、L7、L9
边界案例	常规规则可能失效或需要调整的非常规情境。	L2、L3、L5、L7
技能	可调用流程，包含输入、输出、依赖、检查和证据引用。	L2、L3、L4、L8、L9

除六类核心经验资产外，部分内容可根据应用需求以扩展形式纳入系统。例如，话术风格和角色偏好可以作为技能资产的可选配置，知识缺口则作为显式元数据保留，并用于触发后续补充采集或人工审核，而无须单独设置顶层经验库。基于这一设计，本文对核心经验资产的数据字段进行统一，同时保留扩展机制，以支持商业部署中根据具体行业和任务增加领域专用的资产类型。

本技术报告采样样本共形成 13,113 条组织经验资产，其中规则库 3,550 条、最佳实践库 2,892 条、技能库 1,955 条、边界案例库 1,948 条、约束库 1,623 条、负样本库 1,145 条。从功能上看，规则与最佳实践主要为任务中的判断和操作提供参考；约束、负样本和边界案例则用于补充适用条件、风险提示及异常情形；技能进一步将相关经验组织为可被智能体直接调用的任务流程。

在保留逐次工具调用记录的 53 道评测题中，C 组有 46 题检索规则库、35 题检索边界案例库、33 题检索最佳实践库、28 题检索约束库、18 题检索负样本库，同时有 46 题调用技能。这些调用记录反映了不同经验库在实际任务执行中的组合使用方式，也为分析各类资产在检索、推理和技能执行过程中的作用提供了依据。

在经验检索与使用过程中，需要明确区分负样本与边界案例。负样本主要记录已经出现的不当做法、失败过程及其纠正措施，用于提示模型避免重复相同错误；边界案例则描述常规规则可能需要调整或不再适用的特殊情境，即使该情境尚未实际导致失败，也具有提示价值。两类资产分别支持错误预防与例外处理；最佳实践则同时记录实践结果、适用条件和复用要求，使智能体能够按具体情境选择合适的经验。

技能属于复合型经验资产。它按照统一的记录规范引用相关规则、约束、最佳实践及案例，并进一步明确任务流程的输入条件、执行步骤、状态转移和输出结果，从而将分散的经验内容组织为可由智能体调用和执行的结构化流程。

3.6 证据、审核与不确定性

在经验转换过程中，系统应持续记录内容的来源类型，包括直接观察、从业者陈述以及由模型提出的候选内容。模型基于已有材料提示待补充的关系，并将根据行为记录重构的判断依据作为候选解释提交审核，与直接观察和从业者陈述分别保存。本文所称的蒸馏主要指从原始材料中进行经验抽取、整理与融合，不表示通过教师模型训练学生模型的知识蒸馏过程。

审核状态与置信度需要分别记录。具体而言，抽取置信度用于衡量解析过程是否准确恢复了原始陈述；证据充分性用于判断现有来源是否足以支撑该陈述；适用性则用于判断该陈述能否用于当前任务或特定情境。三者分别衡量抽取准确性、来源支持程度和任务匹配程度，系统独立保存这些信息，支持审核人员逐项检查和判断。

经验资产在生命周期中可以经历候选、已审核、启用、暂停和退役等状态。审核阶段主要检查资产内容、证据依据及其声明的适用范围；资产在正式启用前，还需通过相应的部署与运行检查。当已有资产需要

纠正或更新时，系统应生成新的资产版本，并保留其与旧版本之间的替代关系。对于已经被撤销或判定无效的经验归纳，仍应保留相关原始案例，以便追溯经验的演变过程。

本次整理的组织经验资产均保留经验库版本和条目标识，可据此核对不同资产之间的引用与版本关系。与此同时，评测过程还应记录实际使用的语料版本、经验资产版本及运行配置，从而保证实验结果能够被复核，并支持模型、语料或经验资产更新后的回归测试。

3.7 图结构与面向智能体的使用要求

实体图用于组织任务中的对象及其关系，事件图和依赖图则用于描述任务推进过程及不同步骤之间的联系。图中的边按照语义区分为时间先后、流程依赖、一般关联以及显式提出的因果假设等类型。对于单个案例，事件之间的顺序关系可以表示为无环结构；对于包含重复操作或循环决策的流程，则可通过重复事件实例或独立的状态机进行表达。边类型显式区分流程依赖、一般关联与因果假设，使不同关系的含义清晰可辨。

一项经验资产只有在使用方能够明确理解其含义、适用条件、证据来源和允许用途，并且能够在前提条件缺失时采取相应处理措施时，才具备供智能体使用的条件。因此，经验接口需要提供机器可读的结构化字段，至少包括任务范围、排除条件、来源引用、审核状态和版本标识；对于技能类资产，还应进一步明确输入、输出、前置条件和执行条件。接口层面的校验主要用于检查必要字段和约束是否完整，而任务评测则进一步检验智能体能否在正确的任务情境下选择并使用相应经验资产。

在上述表示规范下，后续语料建设与组织融合将原始材料转化为可追溯的经验资产；第 7 节进一步通过实际工伤纠纷调解任务，展示这些资产在检索与执行中的应用。

4 经验获取与语料建设

4.1 异构证据采集

经验采集既利用已有资料，也补充记录实际工作过程。已有资料包括案例档案、工作日志、事件复盘、培训材料和演示录像；补充采集则包括从业者访谈、任务观察、应用日志，以及工作过程中产生的传感器、音频和视频记录。具体采集方式取决于任务特点：信息密集型审核流程通常已有较完整的数字记录，而实体操作任务往往需要结合现场观察与事后访谈，才能还原行动调整的原因。材料选择应覆盖关键决策、处理结果和例外情况；访谈对象则应具备相关任务经验，能够解释关键线索并提供可核查的案例。

过程采集应保留任务执行顺序，并区分当时已知的信息与事后获得的信息。访谈可用于追问遗漏的观察、被否决的备选方案，以及常规流程可能失效的条件，相关内容应标记为事后陈述。对于尚未补齐的测量数据或观察记录，明确标记缺失项，形成后续补充采集清单。

本次授权样本共包含 1,576 份资料，涉及 13 种文件格式，其中 DOCX 567 份、PDF 351 份、JSON 172 份、Markdown 154 份、DOC 131 份、XLSX 95 份，另包括文本、网页、图片、演示文稿和音频等类型。资料内容涵盖案例卷宗、规程、标准、培训材料、访谈、问答、表格数据和脱敏记录。因此，语料处理需要同时支持叙事文本、结构化表格和多模态附件的解析，并保留不同内容之间的对应关系。

4.2 语义对齐

原始记录在保留原文的基础上，对标识、术语、事件边界和计量单位进行统一。对于缩写、口语、地方用语及指代不明的表达，应结合具体情境进行歧义消除。映射记录应同时保留原始表达、规范术语、支




图 6 语料建设中的四类表示。原始材料（S0）整理为案例叙事（S1），再分析决策要素（S2），最后形成结构化候选记录（S3）。虚线在各阶段保留来源追溯关系。

撑语境以及尚未排除的其他解释。对于“稍热”等模糊表述，不应自动转换为数值阈值；只有在测量数据或经审核的领域定义提供依据时，才可进一步映射为数值区间。

多模态数据在处理过程中，应与具体任务事件及相应时间段建立对应关系。对于语音转写、图像识别等处理结果，应保留其不确定性信息及原始来源位置；对于传感器数据，则应记录单位、采样方式以及可获得的校准信息。考虑到转写或识别环节中的错误可能进一步影响后续经验规则和技能的生成，因此，由这些数据提炼出的陈述均应能够追溯至相应的原始记录。

以高血压防治从业者样本为例，其知识资料由《中国高血压防治指南（2024 年修订版）》和《中国高血压临床实践指南（2024 版）》两份指南构成，并配套高血压患者随访信息数据集的 XML 字段定义。两份指南提供诊断、监测和随访依据，字段定义则规定收缩压、舒张压、体质指数、服药依从性、不良反应、转诊原因和下次随访日期等信息的记录方式。语义对齐时，需要将指南中的相关条件与上述字段、单位及取值范围建立对应关系，同时保留指南版本和原文位置。这样，在后续录入随访信息时，系统可以按照统一字段组织数据，并定位相应的指南条目。本例通过 XML 字段定义建立指南文本与随访数据结构的对应关系，实际随访数据在后续业务环节录入。

4.3 叙事重构与结构化抽取

图 6 中的 S0 至 S3 将案例重构与经验归纳分开处理。S0 保存原始材料；S1 按角色、观察、行动和结果组织案例叙事；S2 识别影响决策的关键要素，包括线索、解释、备选方案、计划调整和不确定性；S3 则将带有支撑证据的相关要素进一步表示为结构化记录与图。各阶段生成的记录均与原始材料保持关联，以便后续核查与追溯。

在此基础上，抽取器依据第 3.3 节所述的九层认知语料化技术生成候选资产。知识抽取用于关联术语和实体；注意抽取识别由从业者明确陈述或行为证据支持的关注重点；判断抽取恢复判断条件及其结论；决策抽取记录采取的行动、选择标准和停止条件；联想抽取记录从业者提及的相关案例，但不将案例间的相似性直接视为因果证据；预判抽取记录预测结果及其时间范围；监控抽取记录需要补充信息、复核判断或转交处理的条件；习惯抽取要求具有跨案例的重复证据；约束抽取则区分明确禁止事项与一般偏好。

表 4 核心转换算子及拒绝条件。每个算子同时记录输入版本、输出版本和来源位置。

算子与输入	转换与输出	拒绝或保留为未解决的情况
术语对齐：原始表达及语境	提出规范术语，保留别名、单位和来源片段。	仍存在多种合理解释，或单位换算缺少依据。
陈述抽取：案例叙事	将观察、判断和计划采取的行动拆成独立陈述，并分别关联来源。	提取的陈述没有相应内容支撑。
条件保留：有条件的陈述	恢复触发条件、建议、前提和例外，形成候选规则。	压缩改变了行动、遗漏了例外或更改了前提。
冲突分类：可比较的资产对	判断条件重叠与行动兼容性，区分一致、适用条件不同或存在冲突。	无法确定范围是否重叠，或缺少裁决依据。

具体抽取器可以结合大语言模型提示、规则解析、图处理和领域规则实现。若抽取模块涉及模型训练，还应记录训练数据、训练目标以及独立验证集上的评测结果。无论采用何种实现方式，候选资产均应保留可供审核的结构化字段及相应的支撑证据。

抽取流程可先由模型生成候选内容，再由从业者依据上述标准进行审核。各阶段均保留输入片段、候选输出、修订内容和审核结论，以支持后续核查与追溯。例如，将“在初步受理阶段，判断原因前应先要求核实；适用独立应急流程的情况除外”提炼为规则时，必须同时保留“初步受理阶段”这一适用前提和“独立应急流程”这一排除条件。若压缩后的规则遗漏其中任一条件，则不能通过条件保留审核。

保留条件的转换。 为检查抽取过程是否改变了规则的适用条件，本文作如下定义。对于规则 r ，以 P_r 表示前提， E_r 表示排除条件， a_r 表示建议行动。在预先定义的任务状态集合 Ω 中，其允许适用的范围为

$$D(r) = \{x \in \Omega : P_r(x) = \text{true} \wedge E_r(x) = \text{false}\}. \quad (7)$$

未知值不能证明规则适用。对来源规则 r_s 与抽取规则 r_e ，分别定义新增和丢失的适用范围：

$$B^+(r_e, r_s) = D(r_e) \setminus D(r_s), \quad B^-(r_e, r_s) = D(r_s) \setminus D(r_e). \quad (8)$$

规范化结果应使两个集合均为空，同时保留原有行动含义及必须保留的例外条件。若 B^+ 非空，说明规范化后的表述引入了来源未支持的适用情形；若 B^- 非空，则说明原先覆盖的情形在规范化过程中被删除。对于有意扩大或收窄适用范围的情况，应作为独立修改另行审核。上述集合用于明确范围一致性的检查目标。针对性测试进一步检查任务情境中的条件完整性与适用范围一致性。

4.4 质量控制与语料版本

质量检查分为三个层次。结构检查主要验证记录标识、必填字段、引用有效性和类型一致性；语义审核重点判断现有证据是否能够支撑相关内容，以及声明的适用范围是否具有依据；任务审核则进一步检查资产能否在具体任务中支持有效决策或流程，同时避免掩盖必要前提的缺失。引入其他从业者参与审核，有助于发现原贡献者因长期实践而忽略的歧义和隐含假设，并进一步区分个人习惯与适合推广的通用流程。

重复记录的识别应同时考虑来源派生关系和文本相似性。由同一事件派生出的多份摘要不能视为相互独立的证据。每次实验或部署均应固定所使用的数据版本，并记录对应的原始资料、处理程序、启用资产及审核结论。语料更新后，仍需保留原实验所使用的数据版本，以支持对已报告结果的复核。

样本资料的审核状态。 本次授权样本的原始资料总量约为 1.73 GB。文件清单显示，1,564 份资料标记为审核通过（Approved），4 份标记为未通过（Rejected），另有 8 份未标注审核状态。上述数量按文件统计；任务集合、语料版本和处理配置分别记录，以支持实验结果复核。

在本次内部评测中，引入原始语料检索后，综合得分均值由 A 组的 70.63 提升至 B 组的 79.75，其中“依据充分性与准确性”指标的均值由 62.18 提升至 77.27。该结果表明，语料解析、索引与检索有效增强了回答的依据充分性，并提升了专业任务的整体表现。

5 组织经验融合

5.1 从个人陈述到组织资产

不同从业者的经验可能彼此一致，也可能由于任务条件不同而不同；即使面对相同的任务条件，不同从业者也可能给出不同的建议。若直接合并经验库，容易掩盖这些差异。因此本系统在决定是否融合前，先结合适用条件、支撑证据和审核状态，对相关经验资产进行比较。具体而言，系统首先对齐任务标识、实体、术语和资产类型，再依据语义相似性与适用范围重叠程度筛选需要比较的资产条目。语义相似性仅用于发现潜在相关条目，并不直接构成融合依据。后续比较主要判断三方面：两项资产是否面向同一决策问题，其适用条件是否可能同时成立，以及所建议的判断或行动是否彼此兼容。




图 7 组织融合的四类处理情况及其依据。一致的陈述保留各自依据；适用情境不同的陈述分别保存；结果比较要求案例可比；未解决的矛盾在裁决前保持未启用。融合后的资产同时保留共识依据与适用条件。

5.2 经验一致性、适用条件差异与冲突处理

图 7 展示了组织经验融合的四类处理结果。当多项经验在相同条件下表述一致时，融合后的条目应保留全部独立来源及其派生关系。若不同经验之间的差异实际上源于适用条件不同，则应分别保留相应做法，并通过条件表达式明确各自的适用范围。例如，常规检查流程与异常运行状态下的处理流程不应被折中为单一操作序列。在比较不同方案时，系统结合案例难度、运行环境、可用资源和结果定义整理历史结果，在可比条件下分析流程表现。历史记录用于保留方案的实践依据，受控对比则用于评估方案差异，使融合决策兼顾经验价值与比较条件。

对于确实存在且尚未解决的矛盾，系统应保留各项备选内容，建立冲突关联，并提交后续审核或裁决，而不将争议内容作为无条件启用的规则提供给智能体。审核人员可以根据证据收窄适用范围、要求补充

案例，或判定现有方案均不具备启用条件。同时，审核还应区分规程要求与个人偏好：前者以明确的制度、标准或规范为依据，不应通过简单投票或与个人偏好折中处理。

基于式 (7) 中的适用范围，定义两条规则的重叠区域与冲突区域：

$$O_{ij} = D(r_i) \cap D(r_j), \quad C_{ij} = \{x \in O_{ij} : \text{compatible}(a_i, a_j, x) = \text{false}\}. \quad (9)$$

兼容性依据任务的顺序、资源和规程要求判断；行动不同不一定互相冲突。 C_{ij} 非空时需要裁决；无法确定范围重叠或兼容性时，状态保持待定。若重叠区域为空，可在已检查的任务范围内将两条规则分别保留。上述定义给出比较依据，具体条件和行动是否兼容仍需结合领域知识审核。

以两条示例规则说明条件化融合过程。一条流程适用于初步受理且不存在紧急情况场景，另一条流程适用于初步受理且存在紧急情况场景。当是否存在紧急情况已经明确时，两条流程的适用范围并不重叠，可以分别保留。若两条流程实际上都适用于“初步受理且不存在紧急情况”的场景，但要求采取不同且无法兼容的下一步行动，则应在这一共同适用范围内建立冲突记录，并保留相关资产版本、重叠条件以及尚未解决的结论。若当前尚不能确定是否存在紧急情况，则暂时无法判断应采用哪一条流程，应先补充核实相关信息，而不能直接选择其中一个分支。

样本中的工伤纠纷调解任务同样存在需要根据条件区分处理流程的情况。常规赔偿核算、第三方商业保险赔付和法定工伤保险责任并不是可以直接合并为同一流程的内容，系统需要分别记录保险性质、责任主体、可计入的赔偿项目以及调解权限。若现有资料仅表明“存在保险”，但没有进一步说明保险类型和受益关系，则相关经验的适用性应保持未知，智能体应先补充核实信息，而不能将商业保险自动视为法定工伤待遇的替代。通过分别记录这些条件，可以在后续检索时选择与具体情境相匹配的经验。

5.3 交叉审核与版本管理

其他从业者可同时审核候选资产及其生成过程，重点检查来源依据、适用条件、例外情况、与其他资产的一致性，以及潜在误用风险。审核过程中，可设计仅改变一个关键条件的测试用例，例如测量数据是否可用，或是否出现需要转交处理的情形，以检验资产的适用范围是否表达清楚。融合结果不仅包括形成的组织资产，还应保留相应的决策记录，包括哪些输入被合并、哪些内容分别保留、所依据的判断以及仍未解决的问题。每次更新均生成新的资产版本。若规则修订影响已有技能，可通过依赖关系定位需要重新验证的技能。版本记录同时保留各从业者的原始贡献，并支持追溯特定运行所使用的资产版本。

样本中的审核记录。 本技术报告采集样本中的组织经验资产按经验库和版本进行保存。其中，8 位资深从业者的记录包含 37 个已完成的“交叉验证”任务，覆盖六类经验库，共形成 818 条候选记录。这里的“已完成”表示比较、评分和记录保存等流程已经结束，人工确认状态则单独记录。其中，9 条已完成人工验证，331 条标记为待人工验证。将自动检查结果与人工审核状态分别保存，可以更准确地反映每条经验当前所处的处理阶段。

以入选的工伤纠纷调解从业者为例，两次规则库审核均基于同一来源版本，每次涉及 37 条来源资产和 21 条候选记录，并保留相应的处理状态。这些记录完整关联候选经验的来源及审核过程。三组配置评测验证了组织经验资产在下游任务中的整体价值；后续可通过单人经验库、直接合并和按情境融合等配置对比，进一步细化融合方法的贡献。

6 技能构建与智能体集成

6.1 技能的调用与执行规范




图 8 技能筛选与执行。检索保留启用、已授权且适用条件为真或未知的候选资产；调用要求前提满足并通过行动检查。信息缺失时先澄清，再重新检查任务状态；行动被拒绝时可升级处理。实际行动与升级处理均记录在案，强约束独立于检索排序生效。

技能（Skill）将九层认知语料化技术形成的经验资产组织为可供智能体调用的流程。其执行规范包括适用条件、输入要求、输出结构、有序步骤、工具依赖、约束、停止条件、证据引用及版本信息。这些要素将经验内容转化为输入明确、过程可检查、结果可核验的可调用技能。技能构建以审核后的资产为基础。其中，规则用于支持判断及状态转移，最佳实践提供候选流程，约束与负样本定义检查项，边界案例指明何时应暂停或调整常规流程。话术可作为特定步骤的辅助内容，但不单独构成完整技能。依赖列表记录每个流程要素由哪些资产支持，使规则或约束的纠正能够触发针对性的重新验证。

系统在推理阶段通过检索与调用使用外部经验资产，无需重新训练基础模型即可更新规则、约束或技能。经验资产修订后，应通过回归评测检查修正内容是否生效，以及无关任务是否出现退化。

6.2 筛选与执行

以下定义经验资产的筛选与执行契约。令 $\mathcal{A}$ 为经验资产集合， $\sigma(r)$ 为资产状态， $\phi_r(x)$ 为结合适用前提与排除条件得到的三值适用性， $\text{access}(r, x)$ 为访问权限。给定任务状态 x ，候选检索首先保留启用、已授权，且适用条件为真或未确定的资产。实际调用采用更严格的资产子集：

$$\mathcal{R}_x = \{r \in \mathcal{A} : \sigma(r) = \text{active}, \text{access}(r, x) = \text{allowed}, \phi_r(x) \neq \text{false}\}, \quad (10)$$

$$\mathcal{X}_x = \{r \in \mathcal{R}_x : \phi_r(x) = \text{true}\}. \quad (11)$$

检索和相关性排序在 $\mathcal{R}_x$ 内进行。对于高度相关但前提未确定的资产，智能体可以有针对性地提问，或请求补充观察信息。只有执行集合 $\mathcal{X}_x$ 中的资产才具备调用候选资格；最终调用还需通过依赖与行动检查；适用条件为假时排除该资产。适用性采用强三值逻辑：缺失值为未知；合取中任一操作数为假则结果为假，仅全部为真时结果为真；对未知值取反仍为未知。未知不能被默认为假，也不能被视为已满足。

排序可考虑相关性、证据支持和时效性，其策略应记入评测清单，避免相关性较高但前提不足的资产被直接执行。

智能体将已有值绑定至技能输入字段，识别缺失前提并提出下一步操作（图 8）。在可能产生实质影响的行动前，检查相关约束与工具权限。强制规程约束的检查独立于相关性排序及前 k 项（top- k ）截断；强制条件未确定时，阻止相应行动。澄清应针对那些取值会改变下一步决策的未确定字段，更新任务状态后重新检查。工具输出仅作为观察信息，不应被视为能够覆盖任务要求或平台控制规则的指令。输出校验检查规定的模式、所报告的证据及停止条件。校验失败时，可有限重试、补充信息、调整计划或转交人工。执行策略不限于固定调用链。技能可以定义分支，但分支条件及其允许的行动必须可检查。意外观察可能使先前成立的前提失效。因此，在行动执行前重新检查，不能完全依赖任务进入时记录的条件。任务记录保存真实执行顺序，包括未成功的尝试和人工干预。

运行日志记录具体资产与技能的调用，为执行过程追溯和分支测试提供依据。下一节结合实际运行案例，观察经九层认知语料化技术处理的经验如何参与判断、边界识别与流程组织。

7 案例分析与任务实测

7.1 实际运行案例：基础模型、原始语料 RAG 与 老师傅智能体配置比较

为考察九层认知语料化技术所形成经验资产在调解任务中的应用，平台对“工伤纠纷调解员老师傅”进行了基础模型、原始语料 RAG 与老师傅智能体三档对比。该老师傅仅有 2 份访谈语料，经处理形成 167 条经验资产，并完成了规则库的交叉验证任务。

其中一个代表性任务要求判断员工下班途中绕路接孩子发生交通事故是否属于工伤，同时说明需要核实的路线、时间和目的证据，并给出调解过程中争议焦点的处理顺序。基础模型能够给出一般性的分析框架和证据清单，但没有引用具体法规，也未明确区分调解与工伤认定的程序边界；原始语料 RAG 能够引用《工伤保险条例》并提出调解步骤；老师傅智能体进一步调用“调解请求判断与聚焦技能”，结合规则库与非常规情形库，对工伤认定边界、调解权限及高风险事项进行区分，并生成了结果文件。该案例的 8 个比较项中，老师傅档均取得最优，其中 1 项与原始语料 RAG 档并列最优。

表 5 工伤纠纷调解案例的三档智能体对比

对比项	A：基础模型	B：原始语料 RAG	C：老师傅智能体
任务	分析员工下班绕路接孩子途中发生交通事故是否属于工伤，并说明需要核实的证据及调解顺序。	同左。	同左。
主要处理	给出一般性分析框架和证据清单。	引用《工伤保险条例》相关条款，并给出调解步骤。	调用“调解请求判断与聚焦技能”，结合规则库与非常规情形库形成处理方案。
边界处理	未明确区分调解与工伤认定的程序边界。	能够提示部分程序与风险边界。	明确“调解不替代工伤认定”，并区分不同事故情形及相应风险事项。
输出形式	以原则性分析和证据建议为主。	提供法律依据和流程建议。	形成结构化处理路径，并生成结果文件。
对比结果	8 个比较项均为最差。	1 个比较项与 C 档并列。	8 个比较项中 C 档均被评为最优或并列最优。

另一项真实问答涉及十级工伤、非全日制用工及多项赔偿金额的调解分析。基础模型主要停留在法律原则和金额反推，原始语料 RAG 增加了实务核算和调解建议，老师傅智能体则调用调解技能，并结合规则库与最佳实践，将工资认定证据、赔偿项目核算、解除原因判断以及司法确认程序组织为完整处理路径，同时生成《工伤调解案件初步分析》文件。

在该老师傅的自研评测中，8 道题的综合分分别为基础模型档 73.34、原始语料 RAG 档 80.80、老师傅智能体档 90.58，老师傅智能体档相对原始语料 RAG 档提高 9.78 分。三档配置的平均端到端耗时分别为 13 秒、31 秒和 53 秒。这些结果表明，九层认知语料化技术有效补充了原始语料 RAG 中较难稳定获得的任务边界、判断条件和处理流程，提升了专业分析的完整性与可操作性。

为进一步考察这一语料处理方案在不同专业场景中的表现，后续两节给出多领域样本的评测设置与结果分析。

8 评测方案

本节通过系统性对比评测，检验九层认知语料化技术所形成经验语料的应用效果，并结合运行记录分析经验资产与技能的作用。实验覆盖 20 位老师傅、177 道评测题和 531 个三档答题样本。三档分别为基础模型 (A)、原始语料检索 (B) 和老师傅语料配置 (C)。



图 9 主要三组对比方案。直接推理建立仅用模型的参照；原始语料 RAG 衡量访问来源记录的作用；老师傅智能体衡量完整经验指导配置的作用。三档围绕相同任务开展配对评估，采用统一的输入要求与评分标准。

8.1 研究问题与评测范围

本章主要考察相较于基础模型和原始语料 RAG，老师傅智能体能否改善任务表现，并进一步分析收益的可能来源，包括案例表示、专家经验采集、组织融合、技能构建和边界控制。主要任务应有明确输入、有限目标和可评估的输出。AgentBench 及面向网页、企业、桌面和软件任务的基准展示了基于环境的评估方式 [21–25]；工具与用户交互、科学 workflows 基准进一步考察对话一致性和产物验证 [26–28]。调解案例可用于识别缺失事实、选择下一步信息采集操作、按审核后的标准检查回复，或选择升级处理路径。离线评测衡量建议的准确性与可操作性，业务应用评估则进一步跟踪纠纷处理等实际结果。专业写作与人机协作研究提示，应关注任务结果，并以人类或 AI 单独表现中的较优者为基线 [29, 30]。

表 6 本次评测的实验设置与数据构成

项目	设置与规模
评测对象	从已授权用户中随机抽取 20 位老师傅，覆盖金融财务、基层治理、工程质量、安全监管、医疗、调解、应急管理等专业场景
任务总量	177 道评测题；A、B、C 三种配置分别作答，共形成 531 个评测样本
任务难度	简单 8 道，中等 83 道，困难 86 道
运行配置	A：基础模型；B：原始语料 RAG；C：老师傅智能体
评分流程	使用统一评判标准与指标进行七维评分
过程轨迹	5 位老师傅、53 道题保留逐次运行记录，可观察检索、经验库调用与技能执行情况

8.2 评测设计原则

图 9 展示三档对比设计。A 档使用基础模型、任务提示和任务开始时可获得观察信息，不检索领域语料。B 档增加对原始领域记录的检索，仅进行实现检索所需的解析和索引。C 档使用从这些记录中构建的老师傅资产与技能。三档在统一任务、输入要求和评分标准下独立作答，以原始语料访问及经验资产与技能的使用作为主要配置差异。对比设计统一管理模型、采样设置、工具权限与运行资源，任务澄清遵循一致的信息提供规则，使各档结果具备可比性。

B、C 两档以同一批授权原始资料为基础，包括纳入语料的访谈记录：B 档直接检索原始内容，C 档使用由这些资料提炼的经验资产与技能。对比由此检验经验结构化与技能化组织的整体价值，运行记录同步保留检索、技能调用与端到端耗时，以分析效果与资源消耗。评测配置的记录范围包括 B 档的文档解析、分块、索引与检索方式，以及 C 档的语料快照、经验检索与技能版本。后续评测可在同样的信息与资源条件下扩展图检索、记忆机制等基线，进一步比较不同经验利用方式。

8.3 本次实验设置与数据构成

样本数据的处理流程。 老师傅系统目前已经商业化落地，平台积累了大量资深从业者的经验。本次技术报告从已授权用户中随机抽取 20 位资深从业者的样本作为分析数据，包含 1,576 份原始资料，经解析后形成 30,762 个可检索语料片段。在此基础上，个人经验提炼阶段形成 23,024 条个人经验记录，组织融合阶段进一步形成 13,113 条组织经验资产。对应的 Elasticsearch 索引中共包含 43,882 条文档。各阶段的数据通过统一的记录标识进行关联，以保持经验资产从原始资料到检索使用过程中的可追溯性。其中，资料清单记录原始资料的来源、文件格式及审核状态；个人经验记录关联相应贡献者及其案例信息；组织经验资产进一步记录资产类型、版本及其来源关系；索引文档则面向智能体检索与调用，为后续任务执行提供数据支持。

从样本覆盖情况看，本次数据涉及 13 种文件格式。20 位参与经验采集的资深从业者中，有 17 位形成了完整的六类经验资产。基于上述数据，可以进一步分析不同任务场景下原始语料的构成特征、经验资产的分布情况及其在智能体任务中的实际使用情况。

任务构成与运行配置。 在上述授权样本基础上，本次评测围绕 20 位老师傅构建任务集，共形成 177 道评测题，并在 A、B、C 三种智能体配置下分别独立作答，得到 531 个评测回答。评测覆盖金融财务、基层治理、工程质量、安全监管、医疗、调解和应急管理等多类专业场景。实验设置与数据构成见表 6。

本次三档对比聚焦推理阶段的经验利用：通过访问原始语料或结构化经验资产提升任务表现，无需重新训练基础模型。审核后的经验还可为后续模型适配提供监督样本或偏好数据，拓展经验资产的使用方式。

评分与运行记录。 A、B、C 在相同题目下分别作答，经 LLM 按统一标准对结果正确性、成果可操作性、专业判断深度、依据充分性与准确性、工具与技能运用适当性、需求理解准确性以及边界与合规性七个维度评分，权重依次为 22、15、15、15、11、11、11（总和 100）。正文均分按平台报告的老师傅汇总分等权计算；这些源汇总分已做舍入，题级分布和重采样区间则从七维加权分重新计算，因此末位小数可能略有差异。本文汇总值按所示精度采用十进制四舍五入。

评测结果支持按老师傅、领域、难度、任务形态等维度进行配对和分层分析。除最终评分外，平台还保留部分运行过程信息。在具有逐次运行记录的 5 位老师傅、53 道题中，可以直接观察知识库检索、原始语料访问、规则库及其他经验库调用以及技能执行情况。老师傅档在其中 52 次运行中进行了知识库检索，46 次调用技能；规则库、非常规情形库、最佳实践库、约束库和负样本库均有实际调用记录。这些运行轨迹使评测结果能够进一步关联到具体经验资产和技能执行行为，而不仅停留在最终得分层面。

评测物料、运行结果和汇总结果采用统一的数据结构保存。对于每位老师傅，可以同时获得题目数量、三档得分、未通过样本、端到端耗时以及各维度得分等统计结果，并保留题级结果，用于进一步分析不同任务条件下的方法差异。与此同时，任务内容与经验资产保持关联，老师傅智能体在任务执行过程中可检索由原始材料形成的规则、约束、最佳实践、负样本、非常规情形和技能，从而使最终得分能够与具体资产调用和执行行为关联起来。例如，在工伤纠纷调解任务中，老师傅智能体调用“调解请求判断与聚焦技能”，同时结合规则库和非常规情形库补充程序边界、事实核实要求和风险提示，体现了从经验资产到任务执行的完整链路。因此，本次数据集不仅用于比较三种智能体配置的最终表现，也用于观察经验从原始材料、结构化资产到技能调用和任务输出的实际使用过程，并为后续按领域、难度、任务形态、经验资产类型和技能使用情况开展分层分析提供统一基础。

8.4 指标与评判

本次评测以七维加权综合得分衡量任务表现，并以 60 分为阈值统计评分通过率。面向后续业务实测，可进一步采用任务成功率，衡量在预先确定的领域评分标准下完成任务并满足全部强制边界条件的比例。单次运行的成功与否为二值。对预先规定的 K 次随机运行，令 $s_{im} = K^{-1} \sum_{k=1}^K s_{imk}$ 为方法 m 在案例 i 上的平均成功率，其中 $s_{imk} \in \{0, 1\}$ 。方法 m 相对于基线方法 b 的配对差异为

$$\hat{\Delta}_{m,b} = \frac{1}{N} \sum_{i=1}^N (s_{im} - s_{ib}). \quad (12)$$

评分标准、强制判失败条件、重复次数和案例分层权重应在测试前固定。除按部署分布加权的得分外，还应报告各层结果及宏平均。统计单元是原始案例；同一案例中的多个问题、重试或随机运行不能视为独立案例。计划通过案例级重采样估计配对差异的置信区间，同时记录案例数和运行数。所有预先规定的运行均纳入案例均值。本次结果采用老师傅整簇重采样，保留同一老师傅题目之间的关联，报告评分增量的 95% 区间。

次要指标包括事实支持、流程完整性、适用性错误、违规行动、不当拒绝和升级处理质量。证据忠实性关注引用片段能否支撑陈述，而不只是有没有引用。陈述级事实性和引用核验已有相应评测研究 [31, 32]；RAGAs 与 RAGChecker 进一步区分检索质量和生成质量 [33, 34]。引用覆盖率与事实支持应分开报告，即使输出未提供引用，评估人员也应对照来源判断内容是否有据。延迟与词元（token）消耗应在相同运行预算下测量，经验采集和专家审核另计成本。

后续人工评估应随机排列输出，并尽可能隐藏系统身份。评估人员使用预定标准，记录分歧，并对部分样本进行独立复核与裁决。评测记录应包括人员资质、一致性和分歧解决流程。通过模型评分与人工复核相结合，可进一步校准评判一致性并扩展评测规模 [35]。业务应用评估则结合规定观察期内的实际结果与环境记录，检验平台在真实工作流程中的持续价值。




图 10 20 位老师傅的三档综合分。按老师傅等权计算，A、B、C 档均分分别为 70.63、79.75、89.58， $C - B = +9.83$ 、 $C - A = +18.96$ 。20 位老师傅的 C 档综合分均高于对应的 A、B 档。

9 实验结果及分析

如表7所示，对比评测显示，原始语料 RAG 和 老师傅智能体均带来明显的分数增量。按未舍入均值计算，B 相对 A 平均提高 9.13 分，C 相对 B 平均提高 9.83 分。C 相对 B 的提升在多个评分维度上均为正，其中“证据支持”提高 11.1 分，“边界与合规性”提高 9.0 分，与图 12 的维度增量一致。C 相对 B 的老师傅整簇自助法 95% 区间为 [9.20, 10.45]，在样本重采样中保持正向增益。

表 7 三档配置的综合表现。各项得分与评分通过率越高越好，延迟越低越好；各项得分与延迟按老师傅等权汇总，评分通过率按 177 道题等权统计，以综合分 60 分为阈值。

方法	综合分	通过率 (%)	证据支持	边界与合规性	延迟
A: 大模型直接推理	70.63	87.57	62.18	74.52	16.2
B: 原始数据 RAG	79.75	98.87	77.27	79.19	34.0
C: 老师傅智能体	89.58	100.00	88.32	88.23	57.1

9.1 总体综合评分

图 10 展示了 20 位老师傅在 A、B、C 三种配置下的综合评分。按老师傅等权计算，平均分由基础模型档的 70.63 提高到原始语料 RAG 档的 79.75，并进一步提高到老师傅智能体档的 89.58，对应 B-A 平均差为 9.13 分、C-B 平均差为 9.83 分、C-A 总体差异为 18.96 分；同时，20 位老师傅的综合得分均呈现 A<B<C 的阶梯关系。老师傅智能体在全部 20 位老师傅的综合评分上均取得优势；题级比较中，177 道题有 176 道的 C 档得分同时高于 A、B 档，进一步展现了跨任务的一致提升。

9.2 分维度表现




图 11 七维度三档均分，按 20 位老师傅等权计算。老师傅智能体档七个维度的均分为 87.7~91.2，20 位老师傅在每一维度上的 C 档得分均高于对应的 B 档。

图 11 进一步比较了三种配置在七个评分维度上的平均表现。老师傅智能体档在结果正确性、成果可操作性、专业判断深度、依据充分性与准确性、工具与技能运用适当性、需求理解准确性以及边界与合规性七个维度上的平均得分介于 87.7 分至 91.2 分之间，并且 20 位老师傅在每一个维度上的 C 档得分均高于对应的 B 档。老师傅智能体的优势同时体现在结果质量、证据组织、专业判断、任务执行和合规边界等多个方面，体现出全面且一致的能力提升。

9.3 阶段性评分增量

图 12 将 A 到 C 的总体评分变化划分为两个连续阶段：A 到 B 表示加入原始语料 RAG 后的评分变化，B 到 C 表示采用九层认知语料化技术构建的经验资产与技能，相较原始语料 RAG 的评分变化。总体上，B-A 的平均差值为 9.13 分，C-B 的平均差值为 9.83 分，两部分数值接近，表明从基础模型到原始语料 RAG、再到老师傅智能体的两个阶段均带来明显的评分提高。综合上述结果，在统一评测流程下，老师傅智能体在老师傅级总体评分、七个评分维度以及 A→B→C 的阶段性比较中均表现出一致的评分优势。后续机制分析将进一步结合资产调用、技能执行和运行轨迹说明经验资产与技能如何参与任务执行。




图 12 七维度评分增量分解：橙色为原始语料检索阶段的增量 ($B-A$)，绿色为经验与技能配置的额外增量 ($C-B$)，柱顶标注两阶段的总增量 ($C-A$)。各维度均按 20 位老师傅等权计算。

表 8 53 道题对应的 53 次 C 档运行中经验资产与技能的使用情况（可重叠，按运行计数）

资产类型	使用运行数	主要作用及代表性任务
规则库	46	将经验中的判断条件显性化为规则、阈值和处理要求；例如用于防汛调度条件判断和工程质量等级上升条件
最佳实践库	33	提供较稳定的处理流程和操作步骤，用于将经验转化为可执行的任务路径
边界案例库	35	补充常规规则难以覆盖的例外条件、高风险情形和特殊业务边界
约束库	28	限制不允许执行的操作或必须满足的前置条件，支持程序边界和合规检查
负样本库	18	提供典型误判和错误处置模式，用于识别高风险决策和异常情形
技能	46	将检索到的经验进一步组织为步骤、检查项、责任主体和结构化交付物

9.4 增量来源与机制分析

本节结合组织资产规模、运行日志和代表性任务，分析老师傅智能体相对原始语料 RAG 的增量来源。重点考察九层认知语料化技术形成的经验资产在组织、检索与技能调用中的作用，以及资产规模、来源格式与评测表现的关系。

20 位老师傅共形成 23,024 条个人发布条目，经组织融合后形成 13,113 条组织资产。融合过程对重复或相近经验进行归并，并将个人经验进一步整理为组织级结构化资产。不同老师傅的融合幅度存在较大差异，说明组织融合并非固定比例的文本压缩，而是与原始经验的重复度、内容结构和组织方式有关。经融合后，后续检索对象由分散的个人经验条目进一步转化为规则、最佳实践、约束、负样本、非常规情形等结构化资产。

在具有完整逐次运行记录的 5 位老师傅、53 道评测题中，C 档有 52 次执行知识库检索，46 次调用技能；规则库、非常规情形库、最佳实践库、约束库和负样本库分别被调用 46、35、33、28 和 18 次。相比主要依赖原始语料检索的 B 档，C 档在运行过程中会同时使用多种结构化经验资产，并在部分任务中进一步调用技能。表 8 汇总了不同资产类型在当前运行记录中的主要作用。

运行案例进一步体现了不同资产类型之间的分工。例如，在城市防汛防台任务中，规则、最佳实践和非常规情形共同用于水位关系、调度顺序和降级条件判断；在安全管理任务中，负样本和非常规情形用于识别有限空间盲目施救、一般隐患与重大事故隐患等高风险边界；在社会保险稽核任务中，技能进一步将经验组织为核查方案、核查清单、审查表和台账等任务交付物。这些案例表明，结构化资产在实际运行中不仅作为检索内容被引用，也参与了判断条件补充、风险边界识别和任务流程组织。

C 相对 B 的评分差异也不限于“工具与技能运用适当性”这一维度。尽管该维度的增量较大，依据充分性与准确性、专业判断深度、成果可操作性以及边界与合规性等维度也同时提高。进一步将“工具与技能运用适当性”从加权总分中剔除，并将其余维度的权重重新归一化至 100 后，C 相对 B 的平均分差仍约为 9.3 分，与原综合分差 9.83 分接近。这一结果进一步说明，老师傅智能体在证据组织、专业判断和任务结果等方面均具有实质提升。

20 位老师傅在不同语料规模与来源格式下均获得评分提升，原始语料切块数、组织资产数和六库规模与 C 相对 B 的增量之间均未呈现稳定关系。表格材料可形成较多单元格碎片，JSON 材料包含结构字段，文档材料则具有较连续的文本结构。平台对这些异构材料进行统一整理，使不同数据条件下的专业经验均能服务于任务执行。相关性分析表明，评分收益难以由资产数量单独解释，经验内容的组织与任务匹配值得进一步关注。

综合运行日志和案例，可以将当前观察到的 C 档运行方式概括为三个相互衔接的环节：首先，基于九层认知语料化技术形成规则、最佳实践、约束、负样本和非常规情形等资产；其次，在具体任务中检索并组合与问题相关的经验；最后，通过技能将相关经验进一步组织为步骤、检查项和交付物。运行记录完整展示了这些环节在实际任务中的应用，与依据充分性、专业判断、成果可操作性和边界与合规性等维度的评分提升相互印证。本节分析完整配置的运行机制，各组件的独立贡献可通过后续消融实验进一步量化。

9.5 效率分析

在 20 位老师傅、177 道评测题的内部评测中，基础模型、原始语料档和老师傅语料档的老师傅等权平均延迟分别为 16.2 s、34.0 s 和 57.1 s；各老师傅 P90 的均值分别为 21.1 s、41.1 s 和 68.4 s。老师傅语料档的平均延迟约为基础模型档的 3.5 倍、原始语料档的 1.7 倍。在具有逐次运行记录的 5 位老师傅、53 道题中，老师傅语料档有 52 次进行了知识库检索，46 次调用技能。其中规则库被调用 46 次，非常规情形库 35 次，最佳实践库 33 次，约束库 28 次，负样本库 18 次。相同样本中，基础模型档平均耗时 17.4 s，原始语料档 36.2 s，老师傅语料档 59.1 s。

老师傅平台通过 RAG 检索、经验调用与技能执行，提升专业任务的完成质量、判断依据的充分性及结果的可操作性。平台面向业务分析、方案制定和专业审核等以结果质量为核心的任务，在平均约一分钟的处理时间内完成经验检索与任务输出。效率评价综合考察响应时间、结果可靠性及后续人工核验成本。在合理的响应时间范围内，通过必要的检索、经验调用与执行检查提高任务完成效果，是平台设计的主要取向。

10 商业部署

老师傅平台为商业化产品，支持云端使用与本地部署。平台将语料生产、经验资产管理、智能体执行和评测记录分别组织，并通过权限、版本和运行记录控制不同环节的访问。现有实验数据来自 2026 年 9 月 16 日发布版本，后续会持续迭代升级。

10.1 定制化本地部署方案

老师傅平台支持面向客户需求的定制化本地部署，可将语料处理、经验资产管理、检索与智能体执行等服务部署于客户自有服务器或私有云环境，并根据行业特点与业务流程配置领域术语、经验库结构、审核规则及技能流程。对于具有严格保密要求的应用场景，可采用本地模型推理与内网工具服务，将原始资料、经验资产、任务输入、生成结果及运行日志的存储与处理限定在客户环境内，避免业务数据通过外部模型接口或第三方服务传出。同时，通过身份认证、分级授权、访问隔离与操作审计，对数据采集、经验共享和智能体调用实施全过程管理，使客户能够自主控制数据的存储位置、使用范围与访问权限，为敏感业务场景提供数据不出域、访问可控、操作可追溯的部署方案。

11 相关工作

专业经验的获取与组织。 关键决策法和应用认知任务分析围绕具体事件追问，还原常规记录中缺失的线索、判断和策略 [3–5]。组织知识创造研究也关注个人知识如何形成共享实践 [36]。老师傅将这些方法应用于面向智能体的记录契约设计。九个维度将专家判断、行动与反馈转化为可抽取、可审核、可复用的经验表示。

检索与结构化语料。 Dense Passage Retrieval 和 Fusion-in-Decoder 分别研究学习式检索及多段文本融合生成 [37, 38]。Self-RAG 增加检索与自我评判决策，RAPTOR 组织递归摘要 [39, 40]。GraphRAG 和 LightRAG 利用图结构检索相互关联的信息 [7, 41]，HippoRAG 2 进一步研究非参数持续学习 [42]。这些方法均可作为简单原始数据索引的替代方案。仅增加长上下文访问能力，不保证模型使用了相关证据 [43]。本文关注从业者所贡献的经验内容及其适用条件。

记忆与经验复用。 CoALA 区分语言智能体的记忆和行动组件 [44]。Generative Agents 使用经历记录与反思指导模拟行为 [45]；Reflexion 和 ExpeL 从智能体尝试中形成可复用反馈 [46, 47]。A-Mem 与 Mem0 研究结构化或整合的记忆，ACE 与 LangMem 支持上下文演化和持久记忆 [48–51]。老师傅侧重外部采集的从业者陈述、陈述级证据、有条件的分歧，以及实际使用前的审核。智能体自行产生的经验与人类专长是不同证据来源，比较时应保持区分。

技能与执行框架。 Toolformer 研究学习式工具使用，ReAct 将推理与环境交互结合 [8, 52]。Voyager 维护可执行技能，Agent Workflow Memory 从历史轨迹中归纳可复用工作流 [53, 54]。AutoGen、MetaGPT、DSPy 和 AgentScope 提供流程编排或程序构建机制 [9, 55–57]。老师傅可向这些系统提供审核后的内容。本文重点补充的是交付给执行器的流程所需的证据与依赖契约，编排机制本身已有相关研究。

专业与科学工作中的人工智能。 AMIE 研究对话诊断，后续工作将对话人工智能扩展到疾病管理 [58, 59]。科学仪器操作智能体和 Co-Scientist 分别研究工具化流程与科学家指导的发现过程 [60, 61]。这些工作为专业场景中的证据组织、专家评估和任务验证提供了方法参考。本文侧重通过更新外部经验语料改善智能体的任务表现，本次评测不涉及基础模型再训练。

12 结论

本报告介绍以九层认知语料化技术为核心的“老师傅”经验工程平台，将资深从业者的隐性经验转化为可追溯、可复用的结构化资产。平台以六类案例要素、九个抽取维度和六类经验资产连接案例记录、隐

性经验与可调用技能；通过语义对齐、个体蒸馏、组织融合和交叉审核保留来源、条件与分歧，并以明确的输入、步骤、依赖和停止条件贯通任务执行与评测反馈。基于随机抽取的 20 位资深从业者授权样本，平台将 1,576 份原始资料整理为 23,024 条个人经验记录和 13,113 条组织经验资产。在统一标准下开展的 177 道评测题、531 个回答样本的对比评测中，按老师傅报告均分等权汇总，基础模型、原始语料 RAG 和老师傅智能体的综合得分分别为 70.63、79.75 和 89.58。老师傅智能体较原始语料 RAG 提高 9.83 分，七个评分维度均取得提升。运行记录确认，经验资产与技能实际参与了判断条件补充、风险边界识别和任务流程组织。上述结果验证了九层认知语料化技术的有效性：平台将个人隐性经验转化为组织知识资产与智能体能力，在任务质量、依据组织和边界处理等方面取得一致优势，形成了从经验沉淀到能力应用的完整工程路径。

未来，随着经验资产的持续积累与应用场景的拓展，“老师傅”平台有望降低专业经验的沉淀、传承与复用成本，推动分散于个体的实践经验转化为组织可持续积累的知识资产。通过将专家判断、实践方法与执行边界融入智能体的任务流程，平台可为企业人才培养、业务协同和专业服务提供支撑，促进经验传承与智能体能力的协同演进。在此基础上，持续完善经验共享、审核更新与应用反馈机制，有望进一步释放行业经验的长期价值，为人工智能深入专业场景、支持复杂业务决策与执行提供基础。

参考文献

- [1] 国务院. 国务院关于深入实施“人工智能+”行动的意见. 政策文件国发〔2025〕11号, 国务院, 2025.
- [2] 工业和信息化部等八部门. 工业和信息化部等八部门关于印发《“人工智能+制造”专项行动实施意见》的通知. 政策文件工信部联科〔2025〕279号, 工业和信息化部, 2025.
- [3] Gary A. Klein, Roberta Calderwood, and Donald MacGregor. Critical decision method for eliciting knowledge. *IEEE Transactions on Systems, Man, and Cybernetics*, 19(3):462–472, 1989. doi: 10.1109/21.31053.
- [4] Robert R. Hoffman, Beth Crandall, and Nigel Shadbolt. Use of the Critical Decision Method to Elicit Expert Knowledge: A Case Study in the Methodology of Cognitive Task Analysis. *Human Factors: The Journal of the Human Factors and Ergonomics Society*, 40(2):254–276, 1998. doi: 10.1518/001872098779480442.
- [5] Laura G. Militello and Robert J. B. Hutton. Applied cognitive task analysis (ACTA): a practitioner’s toolkit for understanding cognitive task demands. *Ergonomics*, 41(11):1618–1641, 1998. doi: 10.1080/001401398186108.
- [6] Patrick Lewis, Ethan Perez, Aleksandra Piktus, Fabio Petroni, Vladimir Karpukhin, Naman Goyal, Heinrich Küttler, Mike Lewis, Wen-tau Yih, Tim Rocktäschel, Sebastian Riedel, and Douwe Kiela. Retrieval-augmented generation for knowledge-intensive NLP tasks. In *Advances in Neural Information Processing Systems*, volume 33, 2020.
- [7] Darren Edge, Ha Trinh, Newman Cheng, Joshua Bradley, Alex Chao, Apurva Mody, Steven Truitt, and Jonathan Larson. From local to global: A graph RAG approach to query-focused summarization. *arXiv preprint arXiv:2404.16130*, 2024.
- [8] Shunyu Yao, Jeffrey Zhao, Dian Yu, Nan Du, Izhak Shafran, Karthik Narasimhan, and Yuan Cao. ReAct: Synergizing reasoning and acting in language models. In *International Conference on Learning Representations*, 2023.
- [9] Dawei Gao, Zitao Li, Yuexiang Xie, Weirui Kuang, Liuyi Yao, et al. AgentScope 1.0: A developer-centric framework for building agentic applications. *arXiv preprint arXiv:2508.16279*, 2025.
- [10] Sarthak Jain and Byron C. Wallace. Attention is not explanation. In *Proceedings of the 2019 Conference of the North American Chapter of the Association for Computational Linguistics: Human Language Technologies*, pages 3543–3556, 2019. doi: 10.18653/v1/N19-1357.
- [11] Matthew A. Lambon Ralph, Elizabeth Jefferies, Karalyn Patterson, and Timothy T. Rogers. The neural and computational bases of semantic cognition. *Nature Reviews Neuroscience*, 18:42–55, 2017. doi: 10.1038/nrn.2016.150.
- [12] Kimberly L. Stachenfeld, Matthew M. Botvinick, and Samuel J. Gershman. The hippocampus as a predictive map. *Nature Neuroscience*, 20:1643–1653, 2017. doi: 10.1038/nrn.4650.
- [13] Maurizio Corbetta and Gordon L. Shulman. Control of goal-directed and stimulus-driven attention in the brain. *Nature Reviews Neuroscience*, 3:201–215, 2002. doi: 10.1038/nrn755.
- [14] Tirin Moore and Katherine M. Armstrong. Selective gating of visual signals by microstimulation of frontal cortex. *Nature*, 421:370–373, 2003. doi: 10.1038/nature01341.
- [15] Etienne Koechlin, Chrystele Ody, and Frederique Kouneiher. The architecture of cognitive control in the human prefrontal cortex. *Science*, 302:1181–1185, 2003. doi: 10.1126/science.1088545.
- [16] Sebastien Ballesta, Weikang Shi, Katherine E. Conen, and Camillo Padoa-Schioppa. Values encoded in orbitofrontal cortex are causally related to economic choices. *Nature*, 588:450–453, 2020. doi: 10.1038/s41586-020-2880-x.
- [17] Stephen M. Fleming, Rimona S. Weil, Zoltan Nagy, Raymond J. Dolan, and Geraint Rees. Relating introspective accuracy to individual differences in brain structure. *Science*, 329:1541–1543, 2010. doi: 10.1126/science.1191883.
- [18] John G. Kerns, Jonathan D. Cohen, Angus W. MacDonald, III, Raymond Y. Cho, V. Andrew Stenger, and Cameron S. Carter. Anterior cingulate conflict monitoring and adjustments in control. *Science*, 303:1023–1026, 2004. doi: 10.1126/science.1089910.
- [19] Henry H. Yin and Barbara J. Knowlton. The role of the basal ganglia in habit formation. *Nature Reviews Neuroscience*, 7:464–476, 2006. doi: 10.1038/nrn1919.
- [20] Adam R. Aron, Paul C. Fletcher, Ed T. Bullmore, Barbara J. Sahakian, and Trevor W. Robbins. Stop-signal inhibition disrupted by damage to right inferior frontal gyrus in humans. *Nature Neuroscience*, 6:115–116, 2003. doi: 10.1038/nrn1003.

- [21] Xiao Liu, Hao Yu, Hanchen Zhang, et al. AgentBench: Evaluating LLMs as Agents. In *International Conference on Learning Representations*, pages 52989–53046, 2024.
- [22] Shuyan Zhou, Frank F Xu, Hao Zhu, et al. WebArena: A Realistic Web Environment for Building Autonomous Agents. In *International Conference on Learning Representations*, pages 15585–15606, 2024.
- [23] Alexandre Drouin, Maxime Gasse, Massimo Caccia, et al. WorkArena: How Capable are Web Agents at Solving Common Knowledge Work Tasks? In *International Conference on Machine Learning*, pages 11642–11662, 2024.
- [24] Tianbao Xie, Danyang Zhang, Jixuan Chen, et al. OSWorld: Benchmarking Multimodal Agents for Open-Ended Tasks in Real Computer Environments. In *Advances in Neural Information Processing Systems*, volume 37, pages 52040–52094, 2024. doi: 10.52202/079017-1650.
- [25] Carlos E Jimenez, John Yang, Alexander Wettig, et al. SWE-bench: Can Language Models Resolve Real-world Github Issues? In *International Conference on Learning Representations*, pages 54107–54157, 2024.
- [26] Shunyu Yao, Noah Shinn, Pedram Razavi, and Karthik Narasimhan. τ -bench: A Benchmark for Tool-Agent-User Interaction in Real-World Domains. In *International Conference on Learning Representations*, pages 9965–10017, 2025.
- [27] Victor Barres, Honghua Dong, Soham Ray, et al. τ^2 -Bench: Evaluating Conversational Agents in a Dual-Control Environment. *arXiv preprint arXiv:2506.07982*, 2025.
- [28] Ziru Chen, Shijie Chen, Yuting Ning, et al. ScienceAgentBench: Toward Rigorous Assessment of Language Agents for Data-Driven Scientific Discovery. In *International Conference on Learning Representations*, pages 96934–96990, 2025.
- [29] Shakked Noy and Whitney Zhang. Experimental evidence on the productivity effects of generative artificial intelligence. *Science*, 381(6654):187–192, 2023. doi: 10.1126/science.adh2586.
- [30] Michelle Vaccaro, Abdullah Almaatouq, and Thomas Malone. When combinations of humans and AI are useful: A systematic review and meta-analysis. *Nature Human Behaviour*, 8(12):2293–2303, 2024. doi: 10.1038/s41562-024-02024-1.
- [31] Sewon Min, Kalpesh Krishna, Xinxu Lyu, et al. FActScore: Fine-grained Atomic Evaluation of Factual Precision in Long Form Text Generation. In *Proceedings of the 2023 Conference on Empirical Methods in Natural Language Processing*, pages 12076–12100, 2023. doi: 10.18653/v1/2023.emnlp-main.741.
- [32] Nelson F. Liu, Tianyi Zhang, and Percy Liang. Evaluating Verifiability in Generative Search Engines. In *Findings of the Association for Computational Linguistics: EMNLP 2023*, pages 7001–7025, 2023. doi: 10.18653/v1/2023.findings-emnlp.467.
- [33] Shahul Es, Jithin James, Luis Espinosa Anke, and Steven Schockaert. RAGAs: Automated Evaluation of Retrieval Augmented Generation. In *Proceedings of the 18th Conference of the European Chapter of the Association for Computational Linguistics: System Demonstrations*, pages 150–158, 2024. doi: 10.18653/v1/2024.eacl-demo.16.
- [34] Dongyu Ru, Lin Qiu, Xiangkun Hu, et al. RAGChecker: A Fine-grained Framework for Diagnosing Retrieval-Augmented Generation. In *Advances in Neural Information Processing Systems*, volume 37, pages 21999–22027, 2024. doi: 10.52202/079017-0692.
- [35] Lianmin Zheng, Wei-Lin Chiang, Ying Sheng, et al. Judging LLM-as-a-Judge with MT-Bench and Chatbot Arena. In *Advances in Neural Information Processing Systems*, volume 36, pages 46595–46623, 2023. doi: 10.52202/075280-2020.
- [36] Ikujiro Nonaka. A Dynamic Theory of Organizational Knowledge Creation. *Organization Science*, 5(1):14–37, 1994. doi: 10.1287/orsc.5.1.14.
- [37] Vladimir Karpukhin, Barlas Oguz, Sewon Min, et al. Dense Passage Retrieval for Open-Domain Question Answering. In *Proceedings of the 2020 Conference on Empirical Methods in Natural Language Processing (EMNLP)*, pages 6769–6781, 2020. doi: 10.18653/v1/2020.emnlp-main.550.
- [38] Gautier Izacard and Édouard Grave. Leveraging Passage Retrieval with Generative Models for Open Domain Question Answering. In *Proceedings of the 16th Conference of the European Chapter of the Association for Computational Linguistics: Main Volume*, pages 874–880, 2021. doi: 10.18653/v1/2021.eacl-main.74.
- [39] Akari Asai, Zeqiu Wu, Yizhong Wang, et al. Self-RAG: Learning to Retrieve, Generate, and Critique through Self-Reflection. In *International Conference on Learning Representations*, pages 9112–9141, 2024.

- [40] Parth Sarthi, Salman Abdullah, Aditi Tuli, et al. RAPTOR: Recursive Abstractive Processing for Tree-Organized Retrieval. In *International Conference on Learning Representations*, pages 32628–32649, 2024.
- [41] Zirui Guo, Lianghao Xia, Yanhua Yu, et al. LightRAG: Simple and Fast Retrieval-Augmented Generation. In *Findings of the Association for Computational Linguistics: EMNLP 2025*, pages 10746–10761, 2025. doi: 10.18653/v1/2025.findings-emnlp.568.
- [42] Bernal Jiménez Gutiérrez, Yiheng Shu, Weijian Qi, et al. From RAG to Memory: Non-Parametric Continual Learning for Large Language Models. In *International Conference on Machine Learning*, pages 21497–21515, 2025.
- [43] Nelson F. Liu, Kevin Lin, John Hewitt, et al. Lost in the Middle: How Language Models Use Long Contexts. *Transactions of the Association for Computational Linguistics*, 12:157–173, 2024. doi: 10.1162/tacl_a_00638.
- [44] Theodore R. Sumers, Shunyu Yao, Karthik Narasimhan, and Thomas L. Griffiths. Cognitive architectures for language agents. *Transactions on Machine Learning Research*, 2024.
- [45] Joon Sung Park, Joseph O’Brien, Carrie Jun Cai, et al. Generative Agents: Interactive Simulacra of Human Behavior. In *Proceedings of the 36th Annual ACM Symposium on User Interface Software and Technology*, pages 1–22, 2023. doi: 10.1145/3586183.3606763.
- [46] Noah Shinn, Federico Cassano, Ashwin Gopinath, et al. Reflexion: language agents with verbal reinforcement learning. In *Advances in Neural Information Processing Systems*, volume 36, pages 8634–8652, 2023. doi: 10.52202/075280-0377.
- [47] Andrew Zhao, Daniel Huang, Quentin Xu, et al. ExpeL: LLM Agents Are Experiential Learners. *Proceedings of the AAAI Conference on Artificial Intelligence*, 38(17):19632–19642, 2024. doi: 10.1609/aaai.v38i17.29936.
- [48] Wujiang Xu, Zujie Liang, Kai Mei, et al. A-Mem: Agentic Memory for LLM Agents. In *Advances in Neural Information Processing Systems*, volume 38, pages 17577–17604, 2025. doi: 10.52202/085713-0593.
- [49] Prateek Chhikara, Dev Khant, Saket Aryan, et al. Mem0: Building Production-Ready AI Agents with Scalable Long-Term Memory. *arXiv preprint arXiv:2504.19413*, 2025.
- [50] Qizheng Zhang, Changran Hu, Shubhangi Upasani, Boyuan Ma, Fenglu Hong, Vamsidhar Kamanuru, Jay Rainton, Chen Wu, Mengmeng Ji, Hanchen Li, Urmish Thakker, James Zou, and Kunle Olukotun. Agentic context engineering: Evolving contexts for self-improving language models. *arXiv preprint arXiv:2510.04618*, 2025.
- [51] LangChain. LangMem: Introduction and documentation, 2025. Accessed September 12, 2026.
- [52] Timo Schick, Jane Dwivedi-Yu, Roberto Dessi, et al. Toolformer: Language Models Can Teach Themselves to Use Tools. In *Advances in Neural Information Processing Systems*, volume 36, pages 68539–68551, 2023. doi: 10.52202/075280-2997.
- [53] Guanzhi Wang, Yuqi Xie, Yunfan Jiang, Ajay Mandlekar, Chaowei Xiao, Yuke Zhu, Linxi Fan, and Anima Anandkumar. Voyager: An open-ended embodied agent with large language models. *arXiv preprint arXiv:2305.16291*, 2023.
- [54] Zora Zhiruo Wang, Jiayuan Mao, Daniel Fried, and Graham Neubig. Agent Workflow Memory. In *International Conference on Machine Learning*, pages 63897–63911, 2025.
- [55] Qingyun Wu, Gagan Bansal, Jieyu Zhang, et al. AutoGen: Enabling Next-Gen LLM Applications via Multi-Agent Conversations. In *Conference on Language Modeling*, 2024.
- [56] Sirui Hong, Mingchen Zhuge, Jonathan Chen, et al. MetaGPT: Meta Programming for A Multi-Agent Collaborative Framework. In *International Conference on Learning Representations*, pages 23247–23275, 2024.
- [57] Omar Khattab, Arnav Singhvi, Paridhi Maheshwari, et al. DSPy: Compiling Declarative Language Model Calls into State-of-the-Art Pipelines. In *International Conference on Learning Representations*, pages 54928–54958, 2024.
- [58] Tao Tu, Mike Schaekermann, Anil Palepu, et al. Towards conversational diagnostic artificial intelligence. *Nature*, 642(8067):442–450, 2025. doi: 10.1038/s41586-025-08866-7.
- [59] Valentin Liévin, Anil Palepu, Wei-Hung Weng, et al. Towards conversational artificial intelligence for disease management. *Nature*, 655(8125):1292–1299, 2026. doi: 10.1038/s41586-026-10764-5.
- [60] Aikaterini Vriza, Michael H. Prince, Tao Zhou, et al. Operating advanced scientific instruments with AI agents that learn on the job. *npj Computational Materials*, 12(1):160, 2026. doi: 10.1038/s41524-026-02005-0.
- [61] Juraj Gottweis, Wei-Hung Weng, Alexander Daryin, et al. Accelerating scientific discovery with Co-Scientist. *Nature*, 655(8122):487–496, 2026. doi: 10.1038/s41586-026-10644-y.

A 团队成员

老师傅（KUPAS MASTER）的项目团队与研究团队成员如下。

A.1 项目负责人

姓名	单位	职务或职称
王长冕	库帕思	CTO
麻玉超	库帕思	创新产品总监、技术架构师、高级 FDE

A.2 项目成员

姓名	单位	职务或职称
陆徐超	库帕思	算法专家、高级 FDE
张琛	库帕思	AI 产品经理、高级 FDE
孙平	库帕思	AI 工程师、高级 FDE
王嘉正	库帕思	AI 评测专家、高级 FDE
王杉	库帕思	高级 FDE

A.3 研究负责人

姓名	单位	职务或职称
郑庆华	同济大学	同济大学党委书记、中国工程院院士
华先胜	同济大学	工程智能研究院执行院长、长聘特聘教授

A.4 研究成员

姓名	单位	职务或职称
李宏智	同济大学	长聘特聘教授、前美国微软首席研究员和首席架构师
黄建强	同济大学	长聘教授、前阿里城市大脑负责人
汤凯华	同济大学	长聘副教授、2024-2025 全球前 2% 科学家
夏子清	同济大学	助理教授、人因专家
鲁子雨	同济大学	博士生
孙一赫	同济大学	硕士生
陈宣文	同济大学	助理研究员

B 案例研究：系统流程示意

图 13 以社区高血压随访场景说明“高血压防治医师”老师傅的构建与使用流程。用户先限定任务范围、输入和交付内容，导入指南及随访字段定义，整理来源、版本与缺失信息；经语义对齐后，提取判断依据、行动条件及适用例外，形成带来源的候选经验。不同来源的经验经融合和领域医师审核后，组织成具有明确输入、步骤及停止条件的技能，供智能体在约定任务范围内调用，生成带引用及待核实事项的随访输出。最后，在固定题目、模型和输入条件下进行对比评测，将发现的问题反馈至语料、经验或技能环节修订。图中的 XML 提供随访字段定义，供后续业务数据录入使用。



图 13 “高血压防治医师”老师傅的构建、调用与评测迭代流程。

C 详细实验分析

为进一步分析“老师傅”平台的任务表现与运行情况，本节结合三档配置的评测结果、经验资产统计和运行记录，围绕系统整体效果、经验表示与融合、技能执行、边界处理、数据规模、持续更新、跨领域应用及运行成本等方面展开详细分析。下表汇总十项实验分析的问题与结果依据，下文结合数据和运行记录，说明平台在经验构建、任务执行与跨领域应用中的优势及优化方向。

表 9 十项实验分析与结果依据（20 位老师傅、19 类平台行业标签、177 题、531 个回答）。

编号	问题	现有证据
E1	完整产品是否改善任务结果？	随机授权样本的三档评分、题级配对、重采样区间和失败记录。
E2	信息相同时，结构化是否有帮助？	同源资料下完整经验与技能配置的整体评分增量。
E3	表示是否有效且可靠？	资产字段、来源关系、AI 检查与独立记录的人工审核状态。
E4	组织融合是否有效？	个人至组织资产的转换规模、库级版本及融合记录。
E5	技能契约是否改善执行？	技能调用、结果文件生成记录及任务评分。
E6	边界资产是否提高可靠性？	边界评分增量、资产使用与边界判断行的关联。
E7	数据量如何影响效用？	不同规模样本的表现及两阶段评分增量的秩相关。
E8	更新经验能否避免性能退化？	库级版本、重复问题报告及不同运行的检索记录。
E9	哪些经验可跨专家或领域迁移？	多个专业场景分别使用领域语料后的任务表现。
E10	运行成本是多少？	各老师傅的分档端到端延迟和分位数统计。

逐项分析与证据说明

- **E1：完整产品的任务效果。**三档内部对比在 20 位老师傅、177 道考题、531 个回答上完成：基础模型档 70.63 → 原始语料档 79.75 → 老师傅语料档 89.58（+18.96 / +9.83，相对提升 26.8% / 12.3%）；20 位老师傅全部呈 $A < B < C$ 阶梯，逐题配对 176/177（对原始语料档）与 177/177（对基础模型档）；未通过样本 22 → 2 → 0；老师傅等权分差 9.83 的 95% 区间为 [9.20, 10.45]，题目等权分差 9.72 的区间为 [9.02, 10.45]（整簇重采样 100,000 次，种子 20260926）。
- **E2：等量信息下的结构化效果。**在同一批上传语料上完成“原始数据 RAG”与“基于九层认知语料化技术的结构化资产”的配置对照：C 档配置在 B 档基础上再提升 9.83 分（12.3%），在全部 20 位老师傅、7 个维度上方向一致；原始语料检索层贡献 9.13 分。
- **E3：经验资产的表示与可靠性。**组织资产表示已规模化落地：六库合计 13,113 条，每条含触发条件、例外条件、判断逻辑、证据片段、来源追溯与置信度等字段，可直接支撑可核对的引用；交叉验证在 6 类库上完成 37 个作业、818 条候选，486 条标记为通过（59.4%），最佳实践库通过率 70%、37 个作业均分的算术平均为 79.5；组织资产数与可检索切块数之比为 0.02–11.9，体现从表格型到大体量案例型语料的多形态适配能力。
- **E4：组织经验融合。**组织级融合链路已跑通并产出可用资产：个人发布条目 23,024 条经共识沉淀、消歧与场景化标注收敛为组织资产 13,113 条，六库齐全 17/20，组织级六库以统一版本重建并进入同一索引（43,882 条 ES 文档），条目带“融合方式”标注，已具备开展四种融合口径对照的数据基础。
- **E5：技能契约与任务执行。**技能契约将九层认知语料化技术形成的经验资产组织为可执行流程：217 份三档对比报告中老师傅档调用 skill 的有 166 份（76.5%）、生成结果文件的有 116 份（53.5%），另两档无 skill 调用；有逐次运行日志的 53 次运行中，46 次调用 skill、46 次检索规则库；“工具与 skill 运用适当性”维度提升 14.38 分，“成果可操作性”提升 9.89 分，实现了从“给建议”到“交付物”的跃迁。
- **E6：边界资产与可靠性。**观察到边界合规评分提升：边界与合规性维度提升 9.03 分，为原始语料检索层（4.67 分）的 1.9 倍，20 位老师傅中 19 位该维增量超过检索层；命中 corner case、约束或负样本库的报告，其边界类判断行独胜率为 95/99，高于未命中报告的 94/127（74.0%）；个案可追溯至“不得因转出快即认定违规”“已交付即合规属误区”等具体误判提示。
- **E7：数据规模与经验效用。**少量经验同样带来明显增量，结构化组织有效释放经验价值：社区老书记（7 份文件、六库 36 条）综合分 91.36（第 2），工伤纠纷调解员（2 份访谈、167 条）综合分

90.58；六库条目数对 $C - B$ 增量的 Spearman 相关系数仅 0.07，原始切块数对 $B - A$ 的相关系数为 0.61 ($p \approx 0.004$)，提示不同数量指标与两阶段增益的关联不同；跨语料规模两个数量级的 20 位老师傅全部一致领先。

- **E8：经验更新与版本管理。**经验资产支持版本化重建与稳定复现：六库可批量重建并保留库级版本（13 位老师傅的当前版本时间戳前缀相同），组织库随语料演进持续更新；同一题目 19 次重复运行中结论稳定（老会计“权益法投资收益”19 次全部对比行均含老师傅档获胜），另有理财顾问题目跨次命中 1 至 5 类库（含原始语料），具备建立“修正前—修正后”快照对照的条件。
- **E9：跨行业应用与迁移。**跨行业应用已覆盖 19 个行业：20/20 位老师傅在 7 个维度、176/177 道题上方向一致，覆盖消防、能源、公安交警、金融财务、基层治理、调解、港口、经侦、轨道交通、应急管理、人社基金、审计、医疗、生态环境、建筑等场景；多类行业与语料形态下均观察到收益。
- **E10：运行成本与效率。**延迟已有运行记录：老师傅等权平均延迟为 16.2/34.0/57.1 s（老师傅 P90 均值为 21.1/41.1/68.4 s），按三档平均耗时之比计算，老师傅档约为基础模型档的 3.53×、原始语料档的 1.68×，逐位均值 43.6–78.3 s，P95 均值 71.6 s；延迟与检索库数、skill 调用和交付物生成正相关且可解释；本产品所聚焦场景非实时性敏感场景，因此收益以整体准确率优先而非效率优先。

D 实验结果分析图

本章节对实验数据做了进一步的可视化分析。其中，题级分数分布和难度分层按 177 道题统计；老师傅级综合分、维度均分及耗时均值按 20 位老师傅等权统计。下文分别标明两种汇总口径，便于对照。

图 14 中三档配置的得分分布逐步向高分区间集中，A、B、C 档的题级均分分别为 70.9、79.9、89.6。以 60 分为通过线，评分通过率由基础模型的 87.57% 提高至原始语料 RAG 的 98.87%，老师傅档达到 100.00%；同时，80 分及以上的比例由 7.3%、58.8% 提高至 99.4%。老师傅配置有效减少了低分回答，并将高分回答覆盖率提升至 99.4%。




图 14 177 道题在三档配置下的 531 个评分结果分布，每档各 177 个。A、B、C 档题级均分分别为 70.9、79.9、89.6；通过率为 87.57%、98.87%、100.00%， ≥ 80 的比例为 7.3%、58.8%、99.4%，未通过题数分别为 22、2、0。

图 15 中，每个散点对应一位老师傅在一种配置下的综合分与单题平均端到端耗时。按 20 位老师傅等权计算，A、B、C 档综合分均值分别为 70.6、79.8、89.6，端到端耗时均值分别为 16.2、34.0、57.1 秒，

图例将耗时取整显示为 16、34、57 秒。按三档未舍入的平均耗时之比计算，C 档约为 A 档的 3.53 倍、B 档的 1.68 倍。老师傅配置以平均 57.1 秒的端到端处理时间获得 89.6 分的综合评分，体现了经验检索与技能执行对专业任务质量的提升，适用于重视判断准确性与输出完整性的业务场景。




图 15 耗时与综合分，每个散点对应一位老师傅的一档配置。A、B、C 档平均耗时分别为 16.2、34.0、57.1 s（图例取整为 16、34、57 s）。按平均耗时之比计算， $C/A = 3.53$ 、 $C/B = 1.68$ 。

图 16 统计了 20 位老师傅共形成的 13,113 条组织经验资产，其中规则与最佳实践合计占 49.1%，其余资产补充技能流程、约束条件、失败经验和特殊情形。不同老师傅的资产规模与类型构成差异较大，17 位形成了完整的六类资产，说明平台能够以多种资产形式组织不同专业场景中的经验内容。

图 17 分析了总样本分布，共包含 1,576 份资料、13 种文件格式，各老师傅的文件数量从 2 份到 378 份不等，资料格式和存储体量也存在较大差异。这反映了专业经验来源的多样性，要求平台同时处理文档、表格、结构化数据及多媒体材料，并保留原始内容之间的关联，为后续经验抽取和组织融合提供基础。

图 18 左图统计采用标准四判断点的 62 份报告，每个判断点含 123 个对比行，老师傅档全部获胜；获胜包含并列胜，同一对比行可计入多个档。右图统计所保留的全部 217 份报告、1,345 个对比行：老师傅档独胜 1,109 行（82.5%）、并列胜 214 行（15.9%），原始语料档独胜 11 行（0.8%），基础模型档独胜或其他结果共 11 行（0.8%）。其中，老师傅档在 166 份报告中调用技能、116 份报告中生成交付文件，显示经验资产与技能已参与具体任务处理和成果生成。

图 19 在 20 位老师傅样本中，组织资产数量与老师傅档相对原始语料 RAG 的评分增量相关性较弱，Spearman 相关系数约为 0.07；原始语料切块数与 RAG 相对基础模型的增量则呈正相关，相关系数为 0.61。这说明评分收益与数据规模的关系随阶段变化，经验资产的组织和使用的为原始语料检索带来进一步增益。

图 20 按实际参与评测的题目及对应难度标签分组，简单、中等和困难任务分别为 8、83、86 道。三组中老师傅档的平均得分分别为 90.8、89.3、89.8，均高于另外两档；相较原始语料 RAG 的评分增量分别约为 8.7、10.0、9.5 分。老师傅档在三个难度组中均取得稳定优势，中等与困难任务的增量分别达到 10.0 分和 9.5 分；各组样本量见图中标注。




图 16 六库共 13,113 条：规则库 3,550、最佳实践库 2,892、skill 库 1,955、corner case 库 1,948、约束库 1,623、负样本库 1,145，17/20 位六库齐全。横轴累计位置在 200 条资产以内采用线性刻度，超过 200 条后采用对数刻度，因此各色段宽度不代表资产类型占比。




图 17 上传语料 1,576 份、1.73 GB、13 种格式，单人文件数 2~378 份，覆盖文档、表格、结构化数据、图像与录音。图中 MB 为十进制兆字节并取整显示，0 MB 表示不足 0.5 MB，并非空语料。




图 18 三档问答判定。左：62 份报告每类 123 个对比行的获胜次数，包含并列胜。右：全部 217 份报告、1,345 个对比行的判定结果，老师傅档独胜 1,109 行（82.5%）、并列胜 214 行（15.9%）。




图 19 规模与评分增量 ($n = 20$)。左：六库组织资产条目数与 $C - B$ 的 Spearman 相关系数为 0.07。右：原始语料切块数与 $B - A$ 的 Spearman 相关系数为 0.61。




图 20 难度分层的题级加权综合得分。简单 ($n = 8$)、中等 ($n = 83$)、困难 ($n = 86$) 三组中，A/B/C 档均分依次为 75.5/82.1/90.8、69.0/79.3/89.3、72.3/80.3/89.8。老师傅档在各难度组的均分均高于另外两档，且均超过 89 分。